



UNIVERSIDAD DE CHILE
FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL

DECOMPOSITION METHOD FOR FEATURE SELECTION PROBLEM

TESIS PARA OPTAR AL GRADO DE
MAGÍSTER EN GESTIÓN DE OPERACIONES

MEMORIA PARA OPTAR AL TÍTULO DE
INGENIERO CIVIL INDUSTRIAL

NICOLÁS ACEVEDO VILLENA

PROFESOR GUÍA:
FERNANDO IVÁN ORDOÑEZ PIZARRO

MIEMBROS DE LA COMISIÓN:

SANTIAGO DE CHILE

2026

Resumen

Resumen

Agradecimientos

Agradecimientos

Tabla de Contenido

1. Introducción	1
2. Objetivos	2
2.1. General	2
2.2. Específicos	2
3. Marco teórico	3
3.1. Feature Selection	3
3.1.1. Métodos de Feature Selection	3
3.1.2. Exact optimization methods for Feature Selection	5
3.2. Literatura sobre Second-Order Cone Programming para el Feature Selection Problem	6
3.3. Literatura sobre métodos de descomposición para problemas de optimización	6
3.3.1. Métodos de descomposición para Linnear Programming	6
3.3.2. Métodos de descomposición para problemas de optimización no lineales	6
4. Metodología	7
4.1. Preliminares	7
4.1.1. Mixed-Integer Quadratic Programming	7
4.1.2. Relajación	7
4.1.3. Second-Order Cone Programming	8
4.2. Método de descomposición	8
4.2.1. Problema maestro	10

4.2.2.	Lagrangiano y Función Dual Lagrangiana del Second-Order Cone Programming	10
4.2.3.	Problemas con la relajación lagrangiana	12
5.	Validación	13
5.1.	Instancias con datos sintéticas	13
5.2.	Parámetros de instancias y ajuste	13
5.2.1.	Hiper-parámetros del problema de optimización	13
5.2.2.	Hiper-parámetros del método de descomposición	13
5.3.	Métricas de interés	13
6.	Resultados	14
6.1.	Comparación de modelos	14
6.1.1.	Tiempos de ejecución	14
6.1.2.	Errores cuadráticos	15
6.1.3.	Cantidad de coeficientes seleccionados	16
7.	Conclusiones	18
	Bibliografía	19

Índice de Tablas

6.1.	Tiempo de ejecución de modelos según el número de observaciones n y el número de atributos m . $M = 10,000$, $\tau = \tilde{\tau}^2 = \kappa = \tilde{\kappa}^2 = \ y - X\beta_{OLS}\ _2^2/M$. .	14
6.2.	Error cuadrático de modelos según el número de observaciones n y el número de atributos m . $M = 10,000$, $\tau = \tilde{\tau}^2 = \kappa = \tilde{\kappa}^2 = \ y - X\beta_{OLS}\ _2^2/M$	16
6.3.	Cantidad de coeficientes seleccionados por cada modelo según el número de observaciones n y el número de atributos m . $M = 10,000$, $\tau = \tilde{\tau}^2 = \kappa = \tilde{\kappa}^2 = \ y - X\beta_{OLS}\ _2^2/M$	17

Índice de Ilustraciones

3.1. Caption	5
6.1. Logaritmo del tiempo de ejecución de modelos según el número de atributos m . $n = 2000$, $M = 10,000$, $\tau = \tilde{\tau}^2 = \kappa = \tilde{\kappa}^2 = \ y - X\beta_{OLS}\ _2^2/M$	15
6.2. Error cuadrático de modelos según el número de atributos m . $n = 2000$, $M = 10,000$, $\tau = \tilde{\tau}^2 = \kappa = \tilde{\kappa}^2 = \ y - X\beta_{OLS}\ _2^2/M$	16

Capítulo 1

Introducción

Dado el problema original de minimización de la suma de los residuos cuadráticos en el contexto de regresión lineal con un gran número de coeficientes (i.e. $\beta \in \mathbb{R}^m, m \gg 1$)

$$\min_{\beta} \|y - X\beta\|_2^2 \quad (1.1)$$

se desea resolver el problema de selección de atributos (o un subconjunto de variables) para obtener un modelo que sea simple de interpretar (con la menor cantidad posible de coeficientes $\beta \neq 0$) y que además entregue resultados en un tiempo prudente. Este es un objetivo es similar al que origina LASSO (Tibshirani, 1996), pero el enfoque de solución propuesto es distinto, ya que LASSO agrega al problema (1.1) una restricción que acota la norma $L1$ por un parámetro t , mientras que la solución que se propone como punto de partida en las siguientes secciones agrega una restricción de tipo “Gran M” al problema (1.1) y un parámetro de castigo a la cantidad de coeficientes distintos de cero. Esto es, como el MIQP propuesto por Bertsimas et al. (2016), pero con una pequeña reformulación.

El objetivo principal es lograr resolver la variación del MIQP antes mencionado hasta quedar con un problema cónico de segundo orden (SOCP) sobre el cual poder aplicar el método de generación de columnas propuesto por Chicoisne (2023), con el que se resuelven problemas de la forma

$$\begin{aligned} (P(\mathcal{X})) \quad \omega(\mathcal{X}) := \min_{x,y} \quad & f(x,y) \\ \text{s.t.} \quad & x \in \mathcal{X}, -g(x,y) \in \mathcal{C} \end{aligned} \quad (1.2)$$

donde f y g son funciones convexas, $\mathcal{C}$ es un cono en un espacio euclidiano y $\mathcal{X}$ es un conjunto de dimensión $n \gg 1$. Con este método se espera resolver el problema en un tiempo menor al que toma resolver el MIQP y el SOCP con los métodos de optimización del estado del arte. Se analizará el poder predictivo y las equivalencias entre los distintos métodos de resolución, además de incorporar en estas al método LASSO.

Capítulo 2

Objetivos

2.1. General

Diseñar un método alternativo de optimización exacta para el problema de selección de atributos dentro de un contexto de minimización de errores cuadráticos, sin restricciones adicionales y considerando conjuntos de datos de gran tamaño (en el orden de cientos de miles de observaciones).

2.2. Específicos

1. Formular un problema simple de optimización exacta que sea capaz de minimizar errores cuadráticos, al mismo tiempo que selecciona los atributos que forman parte de la solución final.
2. Reformular otro problema de optimización, a partir del problema simple basal, que sea capaz de minimizar errores cuadráticos y seleccionar atributos, pero en un tiempo considerablemente menor al del problema inicial.
3. Diseñar una estrategia o método que permita aprovechar la forma del problema reformulado para entregar exactamente la misma solución, en un orden de a lo más un 10 % del tiempo de resolución de este, en instancias de tamaño medio (miles de observaciones).
4. Comprobar que el método propuesto entrega soluciones con sentido, similares a las de los distintos modelos propuestos, junto a otros métodos de selección de variables con optimización exacta de objetivos similares, en tiempos menores a estos.

Capítulo 3

Marco teórico

3.1. Feature Selection

3.1.1. Métodos de Feature Selection

De acuerdo con Miao and Niu (2016), existen dos grandes categorías en las cuales agrupar los de métodos de selección de atributos: según datos etiquetados (*Label Information*) y según estrategias de búsqueda sin etiquetado (*Search Strategy*).

Label Information

Los métodos de selección de características de "Label Information" se basan en la información proporcionada por las etiquetas o clases de los datos. Estos métodos buscan características que estén altamente correlacionadas con las etiquetas o clases relevantes para el problema.

Aquí te describo las tres categorías principales de "Label Information" y sus características:

1. Métodos supervisados: Los métodos supervisados utilizan información de etiquetas o clases conocidas para seleccionar características. Estos métodos buscan características que estén altamente correlacionadas con las etiquetas relevantes para el problema en cuestión. En la selección de características supervisada, el objetivo es encontrar el subconjunto óptimo de características que produzca el mejor rendimiento de clasificación posible en los datos de prueba. Algunos ejemplos de métodos de selección de características supervisados incluyen el análisis discriminante, el análisis de varianza (ANOVA) y el enfoque Wrapper.
2. Métodos semisupervisados: Los métodos semisupervisados utilizan una combinación de datos etiquetados y no etiquetados para seleccionar características. Estos métodos buscan características que sean relevantes para el problema en cuestión y que estén altamente correlacionadas con las etiquetas relevantes. En la selección de características

semisupervisada, el objetivo es encontrar el subconjunto óptimo de características que produzca el mejor rendimiento de clasificación posible utilizando tanto datos etiquetados como no etiquetados. Algunos ejemplos de métodos de selección de características semisupervisados incluyen el enfoque Wrapper y el enfoque Filter.

3. Métodos no supervisados: Los métodos no supervisados utilizan únicamente los datos de entrada sin información de etiquetas para seleccionar características. Estos métodos buscan características que sean altamente informativas y que capturen la variabilidad más relevante de los datos. En la selección de características no supervisada, el objetivo es encontrar el subconjunto óptimo de características que produzca una representación compacta y significativa de los datos. Algunos ejemplos de métodos de selección de características no supervisados incluyen el análisis de componentes principales (PCA), el análisis de factores y los métodos basados en la información mutua.

En resumen, los métodos de selección de características de "Label Information" se basan en la información proporcionada por las etiquetas o clases de los datos. Los métodos supervisados utilizan información de etiquetas conocidas, los métodos semisupervisados utilizan una combinación de datos etiquetados y no etiquetados, y los métodos no supervisados utilizan únicamente los datos de entrada sin información de etiquetas. La elección del método adecuado dependerá del conjunto de datos y del problema específico que se esté abordando.

A continuación, se presentan algunos ejemplos de métodos de selección de características de "Label Information":

1. Análisis discriminante (Discriminant Analysis): busca características que permitan una separación óptima entre las clases.
2. Análisis de varianza (ANOVA): busca características que tengan una varianza significativamente diferente entre las clases.
3. Mutual Information (Información mutua): mide la cantidad de información que comparten las características y las etiquetas.
4. Correlación de Pearson (Pearson Correlation): mide la relación lineal entre las características y las etiquetas.

Estos métodos de selección de características basados en "Label Information" son útiles cuando se dispone de información sobre las clases de los datos y se desea identificar características que estén altamente correlacionadas con las etiquetas relevantes.

Search Strategy

La categoría de "Search Strategy" se refiere a los métodos que buscan el subconjunto óptimo de características para mejorar el rendimiento del modelo de aprendizaje automático. En general, estos métodos involucran la evaluación de múltiples subconjuntos de características y la selección del subconjunto que produce el mejor rendimiento del modelo.

Los métodos de "Search Strategy" se pueden dividir en tres categorías principales:




Figura 3.1: Caption

1. Métodos de filtrado (filter methods): se basan en la evaluación de las características de forma independiente del modelo de aprendizaje automático utilizado. Estos métodos calculan una puntuación para cada característica y se eliminan aquellas con menor puntuación. Ejemplos de métodos de filtrado son Chi-cuadrado, ganancia de información y correlación.
2. Métodos de envoltura (wrapper methods): evalúan las características utilizando un modelo de aprendizaje automático específico y seleccionan las características que maximizan el rendimiento del modelo. Estos métodos son más computacionalmente costosos que los métodos de filtrado, pero pueden dar mejores resultados. Ejemplos de métodos de envoltura son Forward Selection, Backward Elimination y Recursive Feature Elimination.
3. Métodos incrustados (embedded methods): integran la selección de características en el proceso de entrenamiento del modelo de aprendizaje automático. En lugar de seleccionar características antes del entrenamiento, los métodos incrustados seleccionan características durante el entrenamiento para optimizar el rendimiento del modelo. Ejemplos de métodos incrustados son Regresión Lasso y Redes Neuronales.

En resumen, los métodos de "Search Strategy" son un enfoque popular para la selección de características y se utilizan para encontrar el subconjunto óptimo de características que mejora el rendimiento del modelo de aprendizaje automático. Sin embargo, estos métodos pueden ser computacionalmente costosos, especialmente para conjuntos de datos grandes, y la elección del método adecuado dependerá del conjunto de datos y del problema específico que se esté abordando.

3.1.2. Exact optimization methods for Feature Selection

En esta sección se presentan aquellos métodos que utilizan un problema de optimización como punto de base y se buscan resolver con métodos exactos de optimización. Entre ellos, se encuentran las regularizaciones con distintos tipos de norma como lo es LASSO con la norma

euclidiana. El problema de selección general de estos métodos suele resolverse también con una versión relajada del problema de optimización, los cuales minimizan una función de pricing con alguna norma ℓ_p ().

$$\min_{\beta, \lambda} f(\beta) + \lambda \|\beta\|_p, \quad (3.1)$$

donde es la función a minimizar (o maximizar) en el problema original, sin selección de atributos.

3.2. Literatura sobre Second-Order Cone Programming para el Feature Selection Problem

3.3. Literatura sobre métodos de descomposición para problemas de optimización

3.3.1. Métodos de descomposición para Linear Programming

3.3.2. Métodos de descomposición para problemas de optimización no lineales

Capítulo 4

Metodología

4.1. Preliminares

4.1.1. Mixed-Integer Quadratic Programming

El siguiente **problema cuadrático entero mixto** (MIQP) mencionado en el capítulo de Objetivos es el que se propone como punto de partida

$$\begin{aligned} \min_{\beta, z} & \|y - X\beta\|_2^2 + \tau \sum_{i=1}^m z_i \\ \text{s.a.} & -Mz_i \leq \beta_i \leq Mz_i \quad \forall i \in \{1, \dots, m\} \\ & z_i \in \{0, 1\} \quad \forall i \in \{1, \dots, m\} \end{aligned} \tag{4.1}$$

donde y es un vector de n dimensiones con los datos de alguna característica a intentar describir con la matriz de atributos $X \in \mathbb{R}^{n \times m}$, con $m \gg 1$. El escalar M es el hiperparámetro correspondiente a la restricción de “gran M ”, mientras que el hiperparámetro τ tiene el rol de castigar la cantidad de parámetros $\beta_i \neq 0$ a considerar. El valor de M tiene que ser escogido con un valor lo menor posible, pero tal que es mayor que cualquier coeficiente óptimo.

4.1.2. Relajación

Una versión relajada del modelo, en la cual se puede prescindir de la elección de una cota M adecuada, se obtiene al escribir el problema

$$\begin{aligned} \min_{\beta, z, u} & \|y - X\beta\|_2^2 + \tau \sum_{i=1}^m z_i + \kappa \sum_{i=1}^m u_i \\ \text{s.a.} & \beta_i^2 \leq u_i z_i \quad \forall i \in \{1, \dots, m\} \\ & z_i \geq 0 \quad \forall i \in \{1, \dots, m\} \end{aligned} \tag{4.2}$$

donde, sin embargo, se debe encontrar un valor de κ tal que el problema entregue una solución análoga a la de (4.1).

4.1.3. Second-Order Cone Programming

Como se espera llegar a un problema con restricciones cónicas, es útil hacer uso del resultado

$$\beta_i^2 \leq u_i z_i, \quad z_i \geq 0 \quad \Leftrightarrow \quad (u_i - z_i)^2 + (2\beta_i)^2 \leq (u_i + z_i)^2, \quad u_i \geq 0, \quad z_i \geq 0$$

para las restricciones del problema relajado. De esta forma, el problema queda como un **problema con restricciones cónicas de segundo orden (SOCP)**

$$\begin{aligned} \min_{\beta, z, u, \xi} \quad & \xi + \tilde{\tau} \mathbf{e}' z + \tilde{\kappa} \mathbf{e}' u \\ \text{s.a.} \quad & \|y - X\beta\|_2 \leq \xi \\ & \left\| \begin{pmatrix} u_i - z_i \\ 2\beta_i \end{pmatrix} \right\|_2 \leq u_i + z_i \quad \forall i \in \{1, \dots, m\} \\ & u \succcurlyeq 0 \\ & z \succcurlyeq 0 \end{aligned} \tag{4.3}$$

donde se tiene un objetivo lineal, y restricciones de cono de segundo orden. Es necesario notar que los pesos son distintos al de la formulación anterior, ya que ξ es de un orden inferior, dado que el problema (4.1) minimiza la norma al cuadrado, mientras que la relajación minimiza la norma a secas.

4.2. Método de descomposición

El método de descomposición a utilizar se basa en el propuesto en Chicoisne (2023), con un problema de la forma

$$\begin{aligned} (P(\mathcal{X})) \quad \omega(\mathcal{X}) := \min_{x, y} \quad & f(x, y) \\ \text{s.t.} \quad & x \in \mathcal{X}, -g(x, y) \in \mathcal{C} \end{aligned}$$

donde f y g son funciones convexas, $\mathcal{C}$ es un cono en un espacio euclidiano y $\mathcal{X}$ es un conjunto de dimensión $n \gg 1$. La variable y está definida única y exclusivamente por las restricciones cónicas en $\mathcal{C}$.

Al ser $P(\mathcal{X})$ un problema con una gran cantidad de componentes en los vectores $x \in \mathcal{X}$, se propone un método de generación de columnas, donde se acota el problema original resolviendo el

mismo problema, pero en un subconjunto del espacio de soluciones anterior; $P(\mathcal{S})$, con $\mathcal{S} \subseteq \mathcal{X}$. Se debe escoger un $\mathcal{S}$ tal que la cantidad de variables asociadas al problema sea mucho menor en un comienzo. En principio, para el SOCP (4.3), se propone

$$\mathcal{S} = \left\{ x = \sum_{s=1}^K \pi_s \begin{pmatrix} \bar{\beta}^s \\ z^s \\ u^s \end{pmatrix} \mid \pi \geq 0, \sum_{s=1}^K \pi_s = 1 \right\}$$

donde (β_s, z_s, u_s) es una proyección de una solución factible de $P(\mathcal{X})$ en $\mathcal{X}$ y K es lo suficientemente pequeño para tener un problema mucho menos complejo en términos de cantidad de variables. Al ser $P(\mathcal{S})$ un problema con un conjunto factible contenido en el del problema original, se cumple

$$\omega(\mathcal{X}) \leq \omega(\mathcal{S}) \quad .$$

Por otro lado, para escoger una cota inferior del problema, basta con minimizar la relajación lagrangiana de las restricciones cónicas en (4.3) con respecto a las variables del problema original. Es decir, dada la función $\mathcal{L}(\beta, z, u, \xi, \lambda)$, donde λ es un vector de variables duales asociadas a cada restricción cónica, minimizar esta función con respecto a las variables (β, z, u, ξ) .

Para encontrar el óptimo del problema original, se itera con estas cotas, para distintos conjuntos factibles, tal y como se presenta en el Algoritmo 1 descrito por Chicoisne.

Algoritmo 1: An algorithm with caption

Datos: Un problema $P(\mathcal{X})$

Resultado: Una solución óptima de $P(\mathcal{X})$

- 1 Definir $\lambda^0 = 0$, $\mathcal{S}^1 \subseteq \mathcal{X}$ que contenga al menos una solución factible de $P(\mathcal{X})$ y $k = 1$;
 - 2 con el cual se espera obtener el óptimo en un tiempo menor al de (4.3).
 - 3 **mientras** *True* **hacer**
 - 4 Resolver $P(\mathcal{S}^k)$. Sea $(\beta^k, z^k, u^k; \xi^k)$ solución óptima ;
 - 5 Sea λ^k un vector dual asociado a las restricciones $-g(\beta, z, u; \xi) \in C$;
 - 6 **si** $\lambda^k = \lambda^{k-1}$ **entonces**
 - 7 **devolver** $(\beta^k, z^k, u^k; \xi^k)$;
 - 8 Resolver $\mathcal{L}(\beta, z, u, \xi, \lambda^k)$. Sea $(\bar{\beta}^k, \bar{z}^k, \bar{u}^k; \bar{\xi}^k)$ solución óptima ;
 - 9 **si** $(\bar{\beta}^k, \bar{z}^k, \bar{u}^k) \in \mathcal{S}^k$ **entonces**
 - 10 **devolver** $(\beta^k, z^k, u^k; \xi^k)$;
 - 11 Construir $\mathcal{S}^k$, tal que se agregue la solución $(\bar{\beta}^k, \bar{z}^k, \bar{u}^k)$ a los vectores que lo generan ;
 - 12 $k \leftarrow k + 1$;
-

4.2.1. Problema maestro

El problema maestro consiste en un subconjunto de soluciones del *SOCP* que generan S_k en cada iteración, sobre el cual se resuelve el problema maestro

$$\begin{aligned}
\min_{\pi, \xi} \quad & \xi + \tilde{\tau} \mathbf{e}' Z^k \pi + \tilde{\kappa} \mathbf{e}' U^k \pi \\
\text{s.a.} \quad & \|y - X B^k \pi\|_2 \leq \xi \\
& \left\| \begin{pmatrix} U_{i,*}^k - Z_{i,*}^k \\ 2B_{i,*}^k \end{pmatrix} \pi \right\|_2 \leq (U_{i,*}^k + Z_{i,*}^k) \pi \quad \forall i \in \{1, \dots, m\} \\
& \pi \in \Pi,
\end{aligned} \tag{4.4}$$

donde $Z^k, U^k, B^k \in \mathbb{R}^{m \times k}$ son las matrices con las soluciones factibles que generan S_k y Π es el conjunto que contiene las restricciones de naturaleza de π ; cumplir con ser los parámetros de una combinación convexa, cónica, afín o simplemente lineal.

4.2.2. Lagrangiano y Función Dual Lagrangiana del Second-Order Cone Programming

La función lagrangiana que se obtiene al relajar las restricciones del *SOCP* (4.3) es

$$\begin{aligned}
L(x, \lambda) = & \underbrace{\xi + \tilde{\tau} \mathbf{e}' z + \tilde{\kappa} \mathbf{e}' u}_{\text{función objetivo}} - \underbrace{(\psi' \quad \mu) \begin{pmatrix} y - X\beta \\ \xi \end{pmatrix}}_{\text{SOC 1}} - \underbrace{\sum_{i=1}^m (\alpha_i \quad \gamma_i \quad \delta_i) \begin{pmatrix} u_i - z_i \\ 2\beta_i \\ u_i + z_i \end{pmatrix}}_{\text{SOC 2}}
\end{aligned} \tag{4.5}$$

$$= (1 - \mu)\xi + (\psi' X - 2\gamma') \beta + (\tilde{\tau} \mathbf{e} + \alpha - \delta)' z + (\tilde{\kappa} \mathbf{e} - \alpha - \delta)' u - \psi' y, \tag{4.6}$$

donde $\lambda = (\psi, \mu, \alpha, \gamma, \delta)$. Esta función es la cota inferior de la función objetivo del *SOCP* a usar en el Algoritmo 1.

A partir de esta función, se puede construir la función dual lagrangiana $\omega(\lambda) = \inf \{L(x, \lambda) \mid x \in \mathcal{X}\}$ pero teniendo en cuenta algunas consideraciones con respecto a los valores que pueden tomar las variables duales. Esto es,

1. $1 - \mu = 0$, dado que ξ no tiene restricciones en $\mathcal{X}$.
2. $\psi' X - 2\gamma' = 0$, dado que β no tiene restricciones en $\mathcal{X}$.
3. $\tilde{\tau} \mathbf{e} + \alpha - \delta \succcurlyeq 0$, dado que $z \succcurlyeq 0$ en $\mathcal{X}$.
4. $\tilde{\kappa} \mathbf{e} - \alpha - \delta \succcurlyeq 0$, dado que $u \succcurlyeq 0$ en $\mathcal{X}$.

Podemos definir entonces el conjunto de todas estas restricciones a partir de la definición de λ , como $\Lambda = \{\lambda \mid \mu = 1, \psi'X = 2\gamma', \tilde{\tau}\mathbf{e} \succcurlyeq \delta - \alpha, \tilde{\kappa}\mathbf{e} \succcurlyeq \delta + \alpha\}$. Así, $\omega(\lambda)$ queda definida como

$$\omega(\lambda) = \begin{cases} -\psi'y & \text{si } \lambda \in \Lambda \\ -\infty & \text{si } \lambda \notin \Lambda. \end{cases} \quad (4.7)$$

El problema dual queda entonces de la siguiente forma

$$\begin{aligned} \min_{\psi, \mu, \alpha, \gamma, \delta} \quad & -\psi'y \\ \text{s.a.} \quad & \mu = 1 \\ & \psi'X = 2\gamma' \\ & \tilde{\tau}\mathbf{e} \succcurlyeq \delta - \alpha \\ & \tilde{\kappa}\mathbf{e} \succcurlyeq \delta + \alpha \\ & \|\psi\|_2 \leq \mu \\ & \|(\alpha_i, \gamma_i)\|_2 \leq \delta_i \quad \forall i \in \{1, \dots, m\}, \end{aligned} \quad (4.8)$$

donde las últimas dos restricciones son de la naturaleza de las variables duales, las que pertenecen al cono dual **algo**. Este problema puede ser reescrito haciendo uso de las restricciones de igualdad, disminuyendo su número de variables.

Sin embargo, se propone además la construcción de otros dos problemas de optimización que acoten al problema original inferiormente, pero que no relajen todos los conos, sino que cada uno relaje un cono general y el otro lo mantenga como restricción.

Relajación lagrangiana del SOC 1

En esta versión, sólo se relaja el primer cono general, por lo que se tiene como objetivo minimizar

$$L_1(x, \lambda) = \xi + \tilde{\tau}\mathbf{e}'z + \tilde{\kappa}\mathbf{e}'u - (\psi' \quad \mu) \begin{pmatrix} y - X\beta \\ \xi \end{pmatrix} \quad (4.9)$$

$$= (1 - \mu)\xi + \psi'X\beta + \tilde{\tau}\mathbf{e}'z + \tilde{\kappa}\mathbf{e}'u - \psi'y, \quad (4.10)$$

pero se mantienen las restricciones del SOC 2, por lo que se resuelve el problema de optimización

$$\begin{aligned} \min_{\pi, \xi} \quad & (1 - \mu)\xi + \psi'X\beta + \tilde{\tau}\mathbf{e}'z + \tilde{\kappa}\mathbf{e}'u - \psi'y, \\ \text{s.a.} \quad & \left\| \begin{pmatrix} u_i - z_i \\ 2\beta_i \end{pmatrix} \right\|_2 \leq u_i + z_i \quad \forall i \in \{1, \dots, m\} \\ & u \succcurlyeq 0 \\ & z \succcurlyeq 0 \end{aligned} \quad (4.11)$$

Relajación lagrangiana del SOC 2

$$L_2(x, \lambda) = \xi + \tilde{\tau} \mathbf{e}' z + \tilde{\kappa} \mathbf{e}' u - \sum_{i=1}^m (\alpha_i \quad \gamma_i \quad \delta_i) \begin{pmatrix} u_i - z_i \\ 2\beta_i \\ u_i + z_i \end{pmatrix} \quad (4.12)$$

$$= \xi - 2\gamma' \beta + (\tilde{\tau} \mathbf{e} + \alpha - \delta)' z + (\tilde{\kappa} \mathbf{e} - \alpha - \delta)' u, \quad (4.13)$$

$$\begin{aligned} \min_{\pi, \xi} \quad & \xi - 2\gamma' \beta + (\tilde{\tau} \mathbf{e} + \alpha - \delta)' z + (\tilde{\kappa} \mathbf{e} - \alpha - \delta)' u \\ \text{s.a.} \quad & \|y - X\beta\|_2 \leq \xi \\ & u \succcurlyeq 0 \\ & z \succcurlyeq 0 \end{aligned} \quad (4.14)$$

4.2.3. Problemas con la relajación lagrangiana

El problema principal de la relajación lagrangiana es la naturaleza de la variable β , la cual no tiene restricciones. De este modo, esta variable siempre puede intentar llegar a valores infinitos al multiplicarla por distintos vectores.

Cota:

$$|x_k| \cdot \|A_k\|_2 - \|A_{\bar{k}} \cdot x_{\bar{k}}\|_2 + c^\top x \leq \|A \cdot x\| + c^\top x, \quad \forall k \in [m]$$

Criterio:

- Si $\|A_k\|_2 \geq |c_k|$, $\forall k \in [m] \Rightarrow$ cota converge
- Si $\exists k \in [m]$ s.t. $\|A_k\|_2 < |c_k| \Rightarrow$ cota diverge

Capítulo 5

Validación

5.1. Instancias con datos sintéticas

5.2. Parámetros de instancias y ajuste

5.2.1. Hiper-parámetros del problema de optimización

5.2.2. Hiper-parámetros del método de descomposición

5.3. Métricas de interés

Capítulo 6

Resultados

6.1. Comparación de modelos

6.1.1. Tiempos de ejecución

Los resultados obtenidos en cuanto a tiempos de ejecución en la optimización de cada modelo para distintas instancias con datos sintéticos se presentan en la Tabla 6.1. En la descripción se presentan los valores de los hiperparámetros involucrados. En principio, para poder tener valores comparables en la función objetivo, se fijan los valores de los castigos τ y κ en el valor $\|y - X\beta_{OLS}\|_2^2/M$ (teniendo en cuenta que las variables binarias que pueden activarse en el peor caso del MIQP son M), donde el vector $\beta_{OLS} = (X'X)^{-1}X'y$. Para los castigos de orden menor, simplemente se ajusta este mismo valor al orden de la función objetivo.

n	m	MIQP (mins)	MIQP relaj. (mins)	SOCP (mins)
2000	10	0.0359	0.0019	0.0021
2000	15	0.0867	0.0024	0.0024
2000	20	0.4049	0.0047	0.0048
2000	25	0.4281	0.0055	0.0063
2000	30	0.4680	0.0089	0.0071
2000	35	2.7760	0.0086	0.0427
2000	40	7.3953	0.0165	0.0115
2000	45	4.5180	0.0133	0.0145
2000	50	5.9823	0.0175	0.0167
2000	55	4.7271	0.0180	0.0183
2000	60	107.3755	0.0223	0.0680
2000	65	468.2318	0.0266	0.0240
2000	70	27.6091	0.0229	0.0271
2000	75	49.9958	0.0280	0.0316
2000	80	4553.4198	0.0261	0.0336

Tabla 6.1: Tiempo de ejecución de modelos según el número de observaciones n y el número de atributos m . $M = 10,000$, $\tau = \tilde{\tau}^2 = \kappa = \tilde{\kappa}^2 = \|y - X\beta_{OLS}\|_2^2/M$.

La Figura 6.1 representa en forma gráfica lo descrito por la Tabla 6.1, pero en escala logarítmica, ya que los tiempos del MIQP (4.1) escapan rápidamente del rango de valores de los otros métodos. Se puede observar que los tiempos de ejecución del MIQP son mayores a los de las otras dos formulaciones, mientras que el MIQP relajado (4.2) y el SOCP (4.3) son casi equivalentes en esta métrica.




Figura 6.1: Logaritmo del tiempo de ejecución de modelos según el número de atributos m . $n = 2000$, $M = 10,000$, $\tau = \tilde{\tau}^2 = \kappa = \tilde{\kappa}^2 = \|y - X\beta_{OLS}\|_2^2/M$.

6.1.2. Errores cuadráticos

Los resultados obtenidos en cuando a errores cuadráticos de la forma $\|y - X\beta_{modelo}\|_2^2$, para cada modelo en distintas instancias con datos sintéticos, se presentan en la Tabla 6.1. Las consideraciones de cada experimento son las mismas que para los tiempos de ejecución de la subsección anterior.

La Figura 6.2 representa en forma gráfica lo descrito por la Tabla 6.2. Se puede observar que las soluciones del MIQP relajado (4.2) y del SOCP (4.3) son equivalentes, pero no así con el MIQP (4.1). Es decir, con los hiperparámetros escogidos no existe la equivalencia entre todos los problemas, por lo que se debe ajustar τ , $\tilde{\tau}$, κ y $\tilde{\kappa}$ hasta quedar con problemas que entreguen soluciones equivalentes.

n	m	OLS	MIQP	MIQP relaj.	SOCP
2000	10	1825.91	1825.91	1869.87	1869.85
2000	15	15866.37	16223.95	18495.94	18495.93
2000	20	55263.74	59760.21	72974.54	72979.37
2000	25	41787.64	45395.03	52587.05	52586.71
2000	30	25808.67	26857.50	31077.15	31077.10
2000	35	79050.23	91135.88	102731.25	102739.58
2000	40	76225.45	87676.79	98691.06	98691.16
2000	45	65488.12	68487.37	81984.19	81983.41
2000	50	76631.70	81544.93	94450.27	94449.65
2000	55	43036.38	46562.82	50995.26	50994.92
2000	60	85143.81	93994.51	108257.14	108230.51
2000	65	104318.88	112350.04	134309.60	134309.57
2000	70	53518.17	56361.17	63726.36	63729.87
2000	75	57807.50	59307.18	68967.11	68966.27
2000	80	145396.98	162933.00	183486.32	183484.60

Tabla 6.2: Error cuadrático de modelos según el número de observaciones n y el número de atributos m . $M = 10,000$, $\tau = \tilde{\tau}^2 = \kappa = \tilde{\kappa}^2 = \|y - X\beta_{OLS}\|_2^2/M$.




Figura 6.2: Error cuadrático de modelos según el número de atributos m . $n = 2000$, $M = 10,000$, $\tau = \tilde{\tau}^2 = \kappa = \tilde{\kappa}^2 = \|y - X\beta_{OLS}\|_2^2/M$.

6.1.3. Cantidad de coeficientes seleccionados

El número de coeficientes final entregado por cada modelo se presenta en la Figura 6.3. El número original de variables es m para cada iteración. Se puede apreciar que en prácticamente todas las iteraciones se eliminan coeficientes y, además, se selecciona un número similar de coeficientes en los tres modelos propuestos.

n	m	MIQP	MIQP relaj.	SOCP
2000	10	10	9	9
2000	15	13	13	13
2000	20	16	15	15
2000	25	20	20	20
2000	30	26	27	27
2000	35	24	24	26
2000	40	28	29	29
2000	45	39	36	36
2000	50	39	39	39
2000	55	45	45	45
2000	60	47	46	48
2000	65	52	52	52
2000	70	60	60	60
2000	75	66	65	65
2000	80	57	60	60

Tabla 6.3: Cantidad de coeficientes seleccionados por cada modelo según el número de observaciones n y el número de atributos m . $M = 10,000$, $\tau = \tilde{\tau}^2 = \kappa = \tilde{\kappa}^2 = \|y - X\beta_{OLS}\|_2^2/M$.

Capítulo 7

Conclusiones

Bibliografia

- Bellman, R. E. (1957). *Dynamic Programming*. Princeton University Press, Princeton, New Jersey.
- Bertsimas, D., King, A., and Mazumder, R. (2016). Best subset selection via a modern optimization lens. *The Annals of Statistics*, 44(2):813 – 852.
- Chicoisne, R. (2023). Computational aspects of column generation for nonlinear and conic optimization: classical and linearized schemes. *Computational Optimization and Applications*.
- Kenney, A., Chiaromonte, F., and Felici, G. (2021). MIP-BOOST: Efficient and Effective L0 Feature Selection for Linear Regression. *Journal of Computational and Graphical Statistics*, 30(3):566–577.
- Miao, J. and Niu, L. (2016). A survey on feature selection. *Procedia Computer Science*, 91:919–926. Promoting Business Analytics and Quantitative Management of Technology: 4th International Conference on Information Technology and Quantitative Management (ITQM 2016).
- Richards, J. A. (2022). *Supervised Classification Techniques*, pages 263–367. Springer International Publishing, Cham.
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society. Series B (Methodological)*, 58(1):267–288.

ESTUDIANTE:

.....

Firma

PROFESOR GUÍA:

.....

Firma