



UNIVERSIDAD DE CHILE

FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS

DEPARTAMENTO DE INGENIERÍA INDUSTRIAL

**CONIC DECOMPOSITION METHOD FOR FEATURE SELECTION
PROBLEM**

TESIS PARA OPTAR AL GRADO DE
MAGÍSTER EN GESTIÓN DE OPERACIONES

MEMORIA PARA OPTAR AL TÍTULO DE
INGENIERO CIVIL INDUSTRIAL

NICOLÁS ACEVEDO VILLENA

PROFESOR GUÍA:
FERNANDO ORDOÑEZ PIZARRO

MIEMBROS DE LA COMISIÓN:

Este trabajo ha sido financiado por:
Agencia Nacional de Investigación y Desarrollo

SANTIAGO DE CHILE

2026

Resumen

Agradecimientos

Agradecimientos

Tabla de Contenido

1. Introducción	1
2. Objetivos	3
2.1. Objetivo general	3
2.2. Objetivos específicos	3
3. Marco teórico	5
3.1. Problema de selección de atributos	5
3.1.1. Métodos de selección de atributos, según el problema al cual se incorporan	7
3.1.2. Métodos de selección de atributos, según la manera en la que se incor- poran al problema	9
3.2. Optimización exacta	11
3.2.1. Problemas de optimización exacta	12
3.2.2. Problemas de optimización convexa	13
3.2.3. Relajación lagrangiana de un problema de optimización	14
3.2.4. Problema dual lagrangiano	15
3.2.5. Caso particular: problemas con restricciones cónicas	16

3.3. Optimización de gran escala	17
3.3.1. Métodos de descomposición en problemas de optimización lineal . . .	18
3.3.1.1. Descomposición de Benders	18
3.3.1.2. Dantzing-Wolfe	19
3.3.2. Métodos de descomposición de problemas de optimización no lineal .	20
3.4. Estado del arte	20
3.4.1. Métodos de selección de atributos con optimización exacta	20
3.4.1.1. LASSO	20
3.4.1.2. Elastic Net	21
3.4.2. Modelos lineales y selección de atributos con optimización cónica . .	22
3.4.3. Método de descomposición para problemas de optimización cónica . .	22
4. Metodología	25
4.1. Modelos de optimización para la selección de atributos	25
4.1.1. Modelo basal: Mixed Integer Quadratic Program (MIQP)	26
4.1.2. Modelo relajado: Quadratic Program (QP)	28
4.1.3. Modelo cónico: Second Order Cone Program (SOCP)	31
4.2. Método de descomposición para el modelo cónico de segundo orden	32
4.2.1. Algoritmo de descomposición para el modelo cónico de segundo orden	34
4.2.2. Construcción de la región factible $\mathcal{S}^k$	34
4.2.3. Problema maestro $P(\mathcal{S}^k)$	36
4.2.4. Relajación lagrangiana $L(\mathcal{X}, \lambda^k)$	38

4.2.4.1.	Relajación de $\mathcal{C}_1$	39
4.2.4.2.	Relajación de $\mathcal{C}_2$	40
4.2.4.3.	Relajación de $\mathcal{C}_1$ y $\mathcal{C}_2$	41
4.2.5.	Sobre la convergencia de la relajación lagrangiana $L(\mathcal{X}, \lambda^k)$	42
4.2.5.1.	Condiciones necesarias para la convergencia de $L(\mathcal{X}_{\overline{\mathcal{C}_1}}, \lambda^k)$.	43
4.2.5.2.	Condiciones necesarias para la convergencia de $L(\mathcal{X}_{\overline{\mathcal{C}_2}}, \lambda^k)$.	45
4.2.5.3.	Condiciones necesarias para la convergencia de $L(\mathcal{X}_{\overline{\mathcal{C}_{1,2}}}, \lambda^k)$.	46
4.2.6.	Soluciones artificiales para problemas relajados divergentes	47
5.	Resultados	51
5.1.	Datos	51
5.2.	Método de descomposición, según el problema relajado	52
5.2.1.	Tiempos de ejecución preliminares, según el problema relajado	52
5.2.2.	Valor objetivo óptimo, según el problema relajado	54
5.3.	Revisión de criterios de convergencia en modelos relajados	57
5.3.1.	Comportamiento de la relajación lagrangiana a través de iteraciones .	57
5.3.2.	Omisión del problema relajado con condiciones de convergencia . . .	59
5.4.	Ajuste de parámetros del método	61
5.4.1.	Construcción del conjunto de soluciones iniciales $\mathcal{S}^0$	61
5.4.1.1.	Construcción de soluciones iniciales	61
5.4.1.2.	Cantidad de soluciones iniciales	64
5.4.2.	Construcción del conjunto factible $\mathcal{S}^k$	67

5.4.2.1.	Tipo de combinación de soluciones	67
5.4.2.2.	Cantidad de soluciones artificiales	68
5.5.	Variación de penalización del modelo	70
6.	Conclusiones	73
	Bibliografía	77

Índice de Tablas

4.1. Resumen de las condiciones necesarias para asegurar la convergencia de las tres versiones de relajación del problema cónico de segundo orden.	47
4.2. Resumen de las condiciones de convergencia y las soluciones artificiales construidas en cada caso cuando existe divergencia del problema relajado. Todas las componentes de soluciones artificiales no explicitadas $j \notin \mathcal{J}_v^k$ son nulas. .	49
5.1. Tiempos de ejecución (en minutos) y valor objetivo para el método de descomposición y sus subproblemas, sin chequeo previo de condiciones de convergencia.	59
5.2. Tiempos de ejecución (en minutos) y valor objetivo para el método de descomposición y sus subproblemas, con chequeo previo de condiciones de convergencia.	60
5.3. Comparación de tiempos de ejecución (en minutos) con y sin revisión previa de condiciones de convergencia, para los tres tipos de relajación.	62
5.4. Caption	64
5.5. Caption	65
5.6. Caption	66
5.7. Caption	69
5.8. Caption	70

5.9. Caption	71
5.10. Caption	72

Índice de Ilustraciones

3.1. Gráfico detallado del <i>Hughes' Phenomenon</i> del libro <i>Supervised Classification Techniques</i> de Richards (2022). La precisión (<i>accuracy</i>) de un modelo mejora con un mayor número de atributos (<i>features</i>) hasta cierto punto, pero, a partir de este, un aumento en la dimensionalidad, produce una disminución en la precisión del modelo.	6
5.1. Tiempos de ejecución con datos sintéticos para distintos números de atributos m , con $n = 10000$ observaciones.	53
5.2. Caption	53
5.3. Caption	54
5.4. Caption	55
5.5. Caption	56
5.6. Caption	56
5.7. Caption	58
5.8. Caption	58
5.9. Caption	59
5.10. Caption	60

Capítulo 1

Introducción

La selección de atributos es un elemento crítico en el campo del aprendizaje automático y el análisis de datos en general. El objetivo de esta selección es identificar aquellos atributos más informativos o relevantes, dentro de un conjunto dado, a la hora de intentar explicar con estos el valor de cierta característica de interés. La selección de atributos ha adquirido gran relevancia en las últimas décadas, debido al aumento exponencial del uso de datos en diversos dominios, con datos cada vez más diversos y de gran tamaño. La capacidad de seleccionar de manera efectiva atributos relevantes, no solo mejora el rendimiento e interpretabilidad de los modelos de aprendizaje automático, sino que también aborda desafíos como los datos de alta dimensionalidad, la complejidad computacional y el sobreajuste.

Dada la importancia de esta técnica, a través del tiempo han existido muchas propuestas sobre cómo llevar a cabo esta tarea. Ejemplos muy reconocidos de esta técnica en el campo de los datos son: el uso de algoritmos genéticos utilizado por Holland (1975), el criterio de ganancia de información propuesto por Quinlan (1986), el método LASSO (Least Absolute Shrinkage and Selection Operator) de Tibshirani (1996) y la selección de atributos secuencial de Kohavi & John (1997).

Los siguientes capítulos se enfocan en una única subcategoría de estos métodos: los que realizan una selección de atributos con optimización exacta, al mismo tiempo en el que minimizan la suma de errores cuadráticos. Dentro de los métodos antes mencionados, el único que entra en esta categoría sería LASSO, el cual minimiza la suma de errores cuadráticos,

sujeto a que la suma de todas las magnitudes de los pesos otorgados a cada atributo, sea menor a un límite impuesto. Se han propuesto otros modelos de optimización exacta para este problema, con lógicas relativamente similares a LASSO. Un ejemplo de esto es el modelo descrito por Bertsimas et al. (2016), donde, en vez de acotar las magnitudes de los coeficientes asociados a cada atributo del problema, se penaliza que dicho coeficiente tome un valor distinto a cero; es decir, resuelve el problema del mejor subconjunto (de atributos) a la vez que minimiza la suma de los errores cuadráticos. El problema de esta modelización del problema es que existen variables enteras, por lo que, para resolver el problema en tiempos competitivos, el conjunto de atributos debe ser de tamaño pequeño a mediano. El problema propuesto por Bertsimas et al. (2016), por ejemplo, puede resolver problemas con miles de observaciones y cientos de atributos, y viceversa, en cosa de minutos.

En este texto se diseña entonces, a partir de modelos como el antes descrito, un método de descomposición, para problemas de selección de variables reescritos en forma de modelos de optimización cónica de segundo orden, basado en el propuesto por Chicoisne (2023). El método propuesto es capaz de resolver problemas de gran magnitud (decenas de miles de variables) en tiempos competitivos, reduciendo el espacio de atributos a uno que sea interpretable por el ser humano.

Capítulo 2

Objetivos

2.1. Objetivo general

Diseñar un método alternativo de optimización exacta para el problema de selección de atributos dentro de un contexto de minimización de errores cuadráticos, sin restricciones adicionales y considerando conjuntos de datos de gran tamaño (en el orden de cientos de miles de observaciones).

2.2. Objetivos específicos

1. Formular un problema simple de optimización exacta que sea capaz de minimizar errores cuadráticos, al mismo tiempo que selecciona los atributos que forman parte de la solución final.
2. Reformular otro problema de optimización, a partir del problema simple basal, que sea capaz de minimizar errores cuadráticos y seleccionar atributos, pero en un tiempo considerablemente menor al del problema inicial.
3. Diseñar una estrategia o método que permita aprovechar la forma del problema reformulado para entregar exactamente la misma solución, en un orden de a lo más un 10 % del tiempo de resolución de este, en instancias de tamaño medio (miles de observacio-

nes).

4. Comprobar que el método propuesto entrega soluciones con sentido, similares a las de los distintos modelos propuestos, junto a otros métodos de selección de variables con optimización exacta de objetivos similares, en tiempos menores a estos.

Capítulo 3

Marco teórico

3.1. Problema de selección de atributos

El problema de selección de atributos (variables, columnas, etc.), o *Feature Selection Problem* en inglés, es una técnica que tiene como objetivo reducir la dimensionalidad de un conjunto de atributos dado. En otras palabras, este método realiza una elección de un subconjunto de atributos relevantes (con respecto a alguna métrica incorporada en el mismo método), a partir de un conjunto de atributos originales, los cuales pueden tener incorporados, incluso, atributos sin relevancia alguna. Los atributos que no forman parte del subconjunto relevante antes mencionado, son eliminados del problema o de la base de datos con la cual se trabaja. Esta técnica suele conducir a mejores resultados en diversos aspectos, como lo son: una disminución en cuanto a costos computacionales, mejoras en la precisión de modelos de aprendizaje, e incluso una mayor interpretabilidad al momento de analizar resultados (Miao & Niu, 2016).

Esta técnica se ha vuelto una necesidad en la actualidad en diversos campos, dado el aumento exponencial del tamaño (tanto en cantidad como en dimensionalidad) de los datos, recopilados y almacenados, que se aprecia año a año. Esto se debe, en gran medida, a la cada vez más masiva cantidad de información recopilada a través de diversas fuentes, como lo son: sensores de diversos tipos, imágenes y videos de vigilancia, redes sociales, entre muchas otras. Los problemas que conlleva este crecimiento acelerado en materia de datos, han sido

estudiados por décadas, en diversos contextos de estudio como la astronomía, estadística, optimización, entre otras disciplinas.

Richard Bellman, en su libro *Dynamic Programming* (Bellman, 1957), ya le daba nombre a uno los contratiempos que aparecen en los problemas con en bases de datos de alta dimensionalidad: *the curse of dimensionality*. Con este término explica que, cuando la dimensionalidad de los datos aumenta, la cantidad de observaciones requeridas para obtener una buena cobertura (representativa) del espacio de atributos, aumenta exponencialmente. Uno de los resultados de una mala cobertura del espacio de atributos, en la actualidad, es que muchas técnicas de aprendizaje automático pueden tener dificultades para aprender, y generalizar a nuevos conjuntos de datos, de manera efectiva (ver Figura 3.1). En este sentido, con una reducción en la dimensionalidad de los datos, sólo disminuye la cantidad de atributos, pero no así la cantidad de observaciones disponibles, por lo que los métodos que reducen la dimensión de un problema aparecen como una alternativa viable para hacer frente a esta “maldición”.




Figura 3.1: Gráfico detallado del *Hughes' Phenomenon* del libro *Supervised Classification Techniques* de Richards (2022). La precisión (*accuracy*) de un modelo mejora con un mayor número de atributos (*features*) hasta cierto punto, pero, a partir de este, un aumento en la dimensionalidad, produce una disminución en la precisión del modelo.

Es necesario mencionar que existen más métodos para reducir la dimensionalidad de un conjunto de datos además de los métodos de selección de atributos, como lo es, por ejemplo,

el Análisis de Componentes Principales (Pearson, 1901), en donde se reduce la dimensionalidad, sintetizando la información de las dimensiones originales en nuevos atributos. Sin embargo, con estas técnicas se pierde la interpretación de cada atributo original por sí solo; mientras que, con los métodos de selección de atributos, se mantienen intactos los atributos del subconjunto relevante seleccionado.

Existen más problemas asociados a una gran cantidad de atributos en conjunto de datos que pueden ser descritos en esta sección, como los revisados en **rellenar**. Sin embargo, los fenómenos ya descritos se consideran como suficiente motivación para dar a entender la relevancia de los métodos de selección de atributos en la actualidad.

En cuanto a los métodos existentes, tal y como se puede inferir de lo anterior, existe una gran diversidad de estos. La elección del método a utilizar en alguna problemática depende de muchos factores, como lo son: la naturaleza misma del problema en cuestión (regresión, clasificación u otro); la manera en la que se quiere incorporar el método de selección al problema (que este sea independiente del modelo utilizado, que por sí mismo sea capaz de resolver el problema, etc.). En esta sección se describen estos dos tipos de clasificación de métodos de selección de atributos, además de mencionar algunos de los métodos más relevantes o reconocidos en la actualidad, en cada una de las categorías.

3.1.1. Métodos de selección de atributos, según el problema al cual se incorporan

Los problemas sobre los cuales se pueden aplicar técnicas de selección de atributos se pueden clasificar en cuatro tipos generales. A continuación, se proporciona una breve definición de cada una de las categorías generales de estos problemas, además de mencionar ejemplos de métodos de selección de atributos que se ocupan en cada uno de los casos.

1. Datos de alta dimensionalidad: La problemática es la dimensión de las bases por sí misma, por lo que el único objetivo es la reducción de su dimensión. En estos casos la selección de atributos no es la única solución, ya que se pueden usar técnicas como Análisis de Componentes Principales.

La técnica de selección de atributos más usual en este tipo de casos es Minimum Variance Thresholding (Hou et al., 2006), en donde se eliminan todos los atributos que no tienen una varianza mayor a cierto límite establecido.

2. Clasificación de texto y procesamiento de lenguaje natural: Se incluyen en esta categoría de problemas aquellos de análisis y también de categorización de textos.

Las técnicas más comunes de selección de atributos para estos problemas son:

- (a) Term Frequency - Inverse Document Frequency statistics (Aizawa, 2003): Basados en las métricas de frecuencia de cada término y de la inversa de la frecuencia entre documentos (entendiendo como documento cualquier texto), se realiza la selección de atributos, dado una estructura de base de datos obtenida a partir de un corpus (colección de documentos).
 - (b) Mutual Information: Se utiliza una medida de dependencia entre los términos de un corpus y un atributo objetivo obtenido a partir de este mismo.
3. Clasificación: Son problemas en donde el objetivo es categorizar las observaciones de una base de datos, según los atributos disponibles, en distintas categorías (o clases) definidas de manera previa; por lo tanto, el atributo objetivo es de naturaleza discreta y no continua.

Las técnicas de selección de atributos más comunes para este tipo de problemas son:

- (a) SelectKBest (Özlem et al., 2021), el cual selecciona los mejores K atributos según algún test estadístico que se define de manera previa.
 - (b) Recursive Feature Elimination (Guyon et al., 2002), el cual es un método iterativo que remueve los atributos menos relevantes con alguna métrica predefinida.
 - (c) Selección de atributos con métodos basados en árboles de decisión (Chen et al., 2020), donde también se escoge de manera previa una métrica que es utilizada como criterio en cada separación de ramas.
4. Regresión: Se asimila a los problemas de clasificación en cuanto a la necesidad de atributo objetivo, pero, en vez de asignarle etiquetas de clase a cada observación, se les asigna un valor continuo asociado a estas. El objetivo de estos problemas es predecir cuál es este valor continuo.

Las técnicas mayormente utilizadas en este tipo de problema son:

- (a) Selección de atributos con métodos basados en árboles de regresión (Chen et al., 2020), donde, de manera similar a los problemas de clasificación, se escoge de manera previa una métrica que es utilizada como criterio en cada separación de ramas.
- (b) LASSO (Tibshirani, 1996): Como ya es mencionado en el Capítulo 1, este método asigna un peso de castigo a la norma uno de los coeficientes de la regresión a la función por minimizar, limitando la cantidad de coeficientes que toman valores distintos a cero. Esto es, se minimiza una suma ponderada de los errores cuadráticos de la regresión y la norma uno de los coeficientes.
- (c) Elastic Net (Zou & Hastie, 2005): La idea general de este método es similar a la de LASSO, siendo la única diferencia la existencia de un tercer término en la función a minimizar: la norma dos de los coeficientes de la regresión. Con esto, no sólo se fuerza que coeficientes menos relevantes tomen valores nulos, sino que, además, se castigan de mayor manera a aquellos coeficientes de gran tamaño del problema original.

El trabajo presentado en este escrito se centra en el cuarto tipo de problema descrito, los problemas de regresión. En específico, en métodos que resuelven un problema de optimización de manera exacta, asignando un peso de castigo a la cantidad de coeficientes distintos de cero de la regresión; por consecuencia, un principio similar y comparable al método LASSO.

3.1.2. Métodos de selección de atributos, según la manera en la que se incorporan al problema

Miao & Niu (2016) clasifican en tres grupos las maneras en las que se puede incorporar un método de selección de atributos a un problema dado, de alguna las categorías antes descritas. A continuación se describen estas tres categorías, además de dar ejemplos de métodos de cada una de ellas.

1. Métodos de filtro (Filters): Estos métodos ocupan métricas estadísticas para asignar un

puntaje a cada uno de los atributos disponibles, y los evalúan de manera independiente al método o modelo que se quiera utilizar para resolver el problema original. Son útiles en problemas de gran tamaño, ya que suelen ser eficientes en términos relativos a los otros tipos de métodos de selección de atributos.

Métodos comunes de filtro son:

- (a) Métodos basados en la correlación (Cui et al., 2010): Métodos con criterios basados en el estadístico de correlación entre cada atributo y la variable objetivo del problema, para medir la relevancia (y permanencia) de cada uno de estos atributos.
 - (b) Variance thresholding (Hou et al., 2006): Ya detallado en la subsección anterior.
 - (c) Test de Chi-cuadrado (Pearson, 1900): Test que mide la independencia de cada atributo con el la variable objetivo de un problema, eliminando, en consecuencia, variables potencialmente irrelevantes para la predicción de este.
2. Métodos de envoltura (Wrappers): Estos métodos ocupan el algoritmo o modelo utilizado para resolver el problema original (usualmente de predicción), para obtener información y evaluar los distintos atributos a partir de sus resultados. Esto es, se prueban los modelos con distintos subconjuntos de los atributos y se mide el rendimiento del modelo, en cuanto a predicción, con cada uno de ellos, para escoger el subconjunto final de atributos.

Métodos comunes de envoltura son:

- (a) Forward selection (Aha & Bankert, 1996): Esta parte con un subconjunto vacío de atributos, y luego incorpora el atributo que tiene mejor rendimiento en cuanto a predicción del atributo objetivo. Sigue así, de manera iterativa, agregando atributos que mejoran el rendimiento, hasta que el rendimiento del modelo baje (criterio de parada).
- (b) Backward elimination (Aha & Bankert, 1996): Es la idea opuesta a Forward selection; es decir, se comienza con el subconjunto de atributos que contiene a todos estos, para luego eliminar atributos poco relevantes (cuya eliminación hace que el rendimiento del modelo mejore), hasta que la eliminación de algún atributo no genera ninguna ganancia en cuanto a rendimiento (criterio de parada).

3. Métodos integrados (Embedded): Estos métodos incluyen la selección de atributos dentro del mismo modelo que resuelve el problema original planteado. No son etapas o ideas independientes del proceso.

Métodos integrados comunes son los ya mencionados en la subsección anterior: LASSO (Tibshirani, 1996), Elastic Net (Zou & Hastie, 2005) y métodos basados en árboles de decisión (Chen et al., 2020). En todos estos métodos, la selección de atributos se realiza al mismo tiempo en el que se resuelve el problema. Son parte del modelo.

Tal y como se puede inferir de la subsección anterior, el presente trabajo se enfoca en los métodos integrados, utilizando optimización exacta como modelo de predicción y selección de atributos en uno mismo. En la subsección 3.4.1 se exploran más alternativas de cómo se puede abordar un problema de optimización de este tipo.

3.2. Optimización exacta

Para comprender qué son los métodos de selección de atributos con optimización exacta, primero hay que definir qué es la optimización exacta. Rothlauf (2011) separa en dos grandes categorías los métodos de optimización: los métodos de optimización exacta que garantizan encontrar una solución óptima (la mínima o máxima solución posible del problema), y los métodos heurísticos de optimización que no son capaces de garantizar una solución óptima (aunque pueden encontrarla en ocasiones). La necesidad de tener heurísticas de optimización nace a partir de la dificultad de resolución de los métodos de optimización exacta, ya que algunos de estos pueden intentar encontrar soluciones en espacios donde es muy complejo encontrar a la solución óptima o con tamaños tan grandes, que los tiempos de ejecución requeridos para encontrar la solución óptima hagan que no sea viable ocupar dichos métodos. Las heurísticas, por otro lado, toman ventaja de la estructura de un problema para encontrar soluciones lo suficientemente cercanas a la solución óptima (dependiendo de cada problema y del objetivo deseado), en tiempos considerablemente más bajos que con optimización exacta. Sin embargo, existen problemas en los que no basta con encontrar una solución lo suficientemente cercana, dado que no hay margen para error, y es necesario ocupar métodos de optimización exacta. Además, un método de optimización exacta brinda una métrica de

comparación y efectividad de una heurística para encontrar soluciones cercanas a la óptima, por lo que casi siempre es necesario poder contar con el método exacto.

3.2.1. Problemas de optimización exacta

En general, un problema de optimización exacta puede definirse de manera genérica, de distintas maneras. Utilizando la notación de Boyd & Vandenberghe (2004c), un problema de optimización es de la forma

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f_0(x) \\ \text{s. a} \quad & f_i(x) \leq b_i, \quad i = 1, \dots, m. \end{aligned} \tag{3.1}$$

En esta formulación, $\min_x f_0(x)$ hace referencia a que este es un problema de minimización de la función $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}$ con respecto al vector variable $x = (x_1, \dots, x_n) \in \mathbb{R}^n$. A la función f_0 se le llama función objetivo del problema, las funciones $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$, $i = 1, \dots, m$, son las funciones de restricción a las que está sujeto (s. a) el problema, y $b_1, \dots, b_m$ son las cotas de estas restricciones. Notar que cualquier problema de optimización con función objetivo escalar puede ser escrito de esta forma, ya que para un problema donde se quiere maximizar una función, basta con tomar f_0 igual a dicha función con signo negativo. En cuanto a las restricciones de desigualdad, se puede aplicar el mismo principio para escribir todas las restricciones como en (3.1), mientras que para las restricciones de igualdad, se puede acotar superior e inferiormente por el mismo valor.

Si se quiere generalizar aún más el concepto de problema de optimización (y simplificar notación), se puede definir a este como

$$\begin{aligned} \min_x \quad & f_0(x) \\ \text{s. a} \quad & x \in \mathcal{X}, \end{aligned} \tag{3.2}$$

donde $\mathcal{X}$ es el conjunto que representa la intersección de todas las restricciones que se aplican a x (la región factible del problema). Esto incluye, desigualdades, igualdades, y, en general, la pertenencia a cualquier tipo de conjunto.

A un vector $x^* \in \mathbb{R}^n$ que cumple $x^* = \operatorname{argmin}_{x \in \mathcal{X}} \{f_0(x)\}$, se le llama solución óptima del problema, o simplemente óptimo del problema. Los algoritmos que resuelven estos problemas de optimización (buscan x^*) aprovechan una estructura general, relajan sus restricciones asignando un costo a esta libertad, y también aprovechan problemas paralelos que acotan al original, para asegurar que un punto es efectivamente el óptimo del problema. Uno de los tipos de problemas más estudiados, para los que existe una gran cantidad de criterios y algoritmos de resolución, son los problemas de optimización convexa. Todos los problemas de optimización exacta abordados en este trabajo pertenecen a esta categoría.

3.2.2. Problemas de optimización convexa

Nuevamente, utilizando la definición de Boyd & Vandenberghe (2004a), un problema de optimización convexa es un problema de la forma

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f_0(x) \\ \text{s. a} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p, \end{aligned} \tag{3.3}$$

donde $f_0, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$ son funciones convexas y $h_1, \dots, h_p : \mathbb{R}^n \rightarrow \mathbb{R}$ son funciones afines. Esta definición es bastante restrictiva, ya que exige que convexidad en función objetivo y en funciones que deben tomar valores negativos y, aún más restrictivo, además de que las restricciones de igualdad, en función de x , deben ser afines. Sin embargo, esta definición no exige que necesariamente existan todas estas restricciones; es decir, problemas con sólo función objetivo convexa, problemas lineales (sólo con restricciones de igualdad afines), y problemas con únicamente restricciones de desigualdad menores a cero que cumplan con la convexidad, también son problemas de optimización convexa.

Existen diversas ventajas en lo que respecta a este tipo de problemas al momento de intentar resolverlos, como, por ejemplo:

1. La región factible $\mathcal{X}$ de un problema convexo es un conjunto convexo, por lo que cualquier mínimo local del problema es, necesariamente, óptimo global del problema; por lo tanto, no existe la posibilidad de tener algoritmos que se estancuen en mínimos locales.
2. Como consecuencia del punto anterior, este tipo de problemas, en casos donde $f_0, \dots, f_m, h_1, \dots, h_p$ son funciones diferenciables, pueden ser resuelto con algoritmos como el descenso del gradiente (Curry, 1944) o el método de Newton (Fletcher, 2013).
3. A través de los años, ha existido un amplio interés por el estudio y comportamiento de este tipo de problemas, lo que ha aportado un gran entendimiento y riqueza teórica que garantiza el comportamiento y soluciones de los algoritmos de optimización para este tipo de problemas. Un importante ejemplo de esto es la suficiencia de las condiciones de Karush–Kuhn–Tucker (Karush, 1939), con lo cual basta ver si un punto del problema convexo cumple con estas condiciones para concluir que dicho punto es el óptimo del problema.

Otro concepto que también cumple con características especiales cuando está asociado a un problema de optimización convexa, y además es necesario para contextualizar los métodos que se presentan en las próximas secciones, es el de la relajación lagrangiana de restricciones de un problema de optimización.

3.2.3. Relajación lagrangiana de un problema de optimización

La idea original de este método es detalla en Lemaréchal (2001), donde se tiene un problema de optimización de cierta función objetivo, y únicamente restricciones de igualdad. En este trabajo, en cambio, el enfoque está en problemas con restricciones de todo tipo. Boyd & Vandenberghe (2004b) definen la función lagrangiana de un problema como una suma de la función objetivo del problema y las sumas ponderadas de las restricciones del problema de la forma

$$L(x, \lambda, \nu) = f_o(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x), \quad (3.4)$$

donde λ_i es llamado el multiplicador lagrangiano asociado a la restricción $f_i(x) \leq 0$, y, así mismo, ν_i es llamado el multiplicador lagrangiano de la restricción $h_i(x) = 0$.

3.2.4. Problema dual lagrangiano

Otra función importante, que deriva de la función lagrangiana, es la función dual lagrangiana. Esta es el mínimo valor que toma la función lagrangiana $L(x, \lambda, \nu)$ con respecto a x , las variables originales del problema; es decir, para cualquier valor de (λ, ν) , esta función es de la forma

$$g(\lambda, \nu) = \inf_{x \in \mathbb{R}^n} L(x, \lambda, \nu) = \inf_{x \in R} \left(f_o(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x) \right). \quad (3.5)$$

Notar que esta función puede divergir si es que no es acotada con respecto a x . En dicho caso, la función dual lagrangiana toma el valor $-\infty$. Si, en cambio, esta función entrega un valor finito en función de (λ, ν) , entonces, para cualquier vector $\lambda \succeq 0$ (con todas sus componente positivas), se cumple que

$$g(\lambda, \nu) \leq f_o(x^*), \quad (3.6)$$

con x^* el óptimo del problema original, ya que este punto cumple con las restricciones del problema $f_i(x^*) \leq 0$ y $h_i(x^*) = 0$, por lo que, junto con con la condición $\lambda \succeq 0$, se cumple $L(x^*, \lambda, \nu) \leq f_o(x^*)$. En particular, como $g(\lambda, \nu)$ toma el mínimo con respecto a x de $L(x, \lambda, \nu)$, con λ vector positivo se cumple que

$$g(\lambda, \nu) = \inf_{x \in \mathbb{R}^n} L(x, \lambda, \nu) \leq L(x^*, \lambda, \nu) \leq f_o(x^*); \quad (3.7)$$

es decir, la función dual lagrangiana es una cota inferior del óptimo de la función objetivo, evaluada en el punto óptimo, del problema original. Además, al ser una cota inferior del valor

óptimo de la función objetivo, por consecuencia, también es cota inferior de cualquier punto factible del problema original cuando $\lambda \succeq 0$.

Teniendo en cuenta que la cota inferior se tiene para todos los valores de $\lambda \succeq 0$ y $\nu \in \mathbb{R}^p$, se puede resolver el problema alternativo

$$\begin{aligned} \max_{\lambda \in \mathbb{R}^m, \nu \in \mathbb{R}^p} \quad & g(\lambda, \nu) \\ \text{s. a} \quad & \lambda \succeq 0, \end{aligned} \tag{3.8}$$

el cual es llamado el problema dual del problema de optimización.

3.2.5. Caso particular: problemas con restricciones cónicas

Antes de presentar los problemas cónicos, se dice que un conjunto C es un cono si para todo elemento $x \in C$, y cualquier ponderador positivo $\theta \geq 0$, se cumple que $\theta x \in C$; es decir, un conjunto es un cono si todas las ponderaciones positivas de sus elementos, también pertenecen a él. Además, se dice que un conjunto C es un cono convexo si para todo par de elementos $x_1, x_2 \in C$, y cualquier par de ponderadores positivos $\theta_1, \theta_2 \geq 0$, se cumple que $\theta_1 x_1 + \theta_2 x_2 \in C$.

Para extender las definiciones de las subsecciones anteriores a más tipos de problema, se presentan entonces los problemas con restricciones cónicas de la forma

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f_0(x) \\ \text{s. a} \quad & -f_i(x) \in K_i, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p, \end{aligned} \tag{3.9}$$

donde $f_i : \mathbb{R}^n \rightarrow \mathbb{R}^{k_i}$, mientras que $K_i \subseteq \mathbb{R}^{k_i}$ son conos propios (convexos, cerrados, con interior no vacío y no contienen líneas).

De manera similar a los problemas presentados en las subsecciones anteriores, se puede definir la función lagrangiana de este tipo de problema cónico como

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i' f_i(x) + \sum_{i=1}^p \nu_i h_i(x), \quad (3.10)$$

donde la diferencia con la definición 3.4 es que a cada $f_i(x)$, se le asocia un vector $\lambda_i \in K_i^*$, donde el asterisco como superíndice indica que se trata del cono dual de K_i^* . Dado un cono C , se define a su cono dual C^* como

$$C^* = \{y : x'y \geq 0, \forall x \in C\}. \quad (3.11)$$

El cono dual es entonces el conjunto de todos los vectores y tales que, el producto interno entre ellos y cualquier elemento de C es siempre positivo. Dicho esto, si x es un punto factible del problema (3.9), entonces se cumple que $-\lambda_i' f_i(x) \geq 0$, por lo que, siguiendo los mismos argumentos que en la subsección 3.2.3, en puntos factibles del problema con restricciones cónicas, la relajación 3.10 es una cota inferior de la función objetivo de dicho problema en el mismo punto. Sigue que todo lo que deriva de la relajación lagrangiana, como el problema dual lagrangiano, es análogo para problemas con restricciones cónicas.

3.3. Optimización de gran escala

Al igual que los datos de gran tamaño es un problema de distintas maneras en distintos tipos de problema, una gran cantidad de variables o restricciones en un problema de optimización aumenta la complejidad de este, principalmente en términos computacionales. La idea de la optimización de gran escala es desarrollar técnicas y algoritmos que puedan resolver este tipo de problemas, entregando una solución suficientemente cercana o idéntica al óptimo del problema original, y en un tiempo de ejecución razonable, dentro de su contexto.

Algunas técnicas para resolver problemas de gran tamaño son los métodos de descomposición, las heurísticas, los algoritmos de aproximación, entre otras. Naturalmente, existe un

balance entre la calidad de la solución de estos métodos y su eficiencia computacional. Para este escrito, se centrará el foco únicamente en los métodos de descomposición.

Los métodos de descomposición son técnicas de optimización en la que se separa un problema de optimización de gran escala en distintos subproblemas de menor tamaño, los cuales, en principio, pueden ser resueltos de manera más eficiente que el problema original. Cada uno de estos subproblemas es resuelto de manera separada, pero las soluciones que genera cada uno sirve como información adicional para el resto de ellos. Estas distintas soluciones entregan, en conjunto, una estructura capaz de entregar la solución al problema de optimización de gran escala.

3.3.1. Métodos de descomposición en problemas de optimización lineal

Los métodos de descomposición más estudiados han sido, en general, los utilizados en problemas lineales (función objetivo y restricciones afines). Entre estos métodos, los dos más reconocidos se detallan en las subsecciones a continuación.

3.3.1.1. Descomposición de Benders

El método de Descomposición de Benders (1962) es un método para resolver problemas de gran escala que siguen una estructura de bloques; es decir, las variables y las restricciones se pueden separar en dos grupos generales, tal y como se puede apreciar en la formulación

$$\begin{aligned}
 \min_{x,y} \quad & c'x + d'y \\
 \text{s. a} \quad & Ax + By \geq b \\
 & y \in Y \\
 & x \geq 0 \quad ,
 \end{aligned} \tag{3.12}$$

donde A y B son matrices con la misma cantidad de filas, y con las mismas columnas que la dimensión de x e y respectivamente, mientras que el vector b es una cota para la relación entre ambas variables. Y es el conjunto que determina la naturaleza de y , y c, d son vectores de costo. El único término que relaciona a ambas variables es la primera restricción, por lo que, sin esta, podrían tratarse como dos problemas independientes con cada variable. Una idea similar se aplica en este método, resolviendo dos tipos de problema en distintas iteraciones, cada uno asociado a una variable distinta, los cuales entregan cotas inferiores y superiores del problema original. De manera general, los dos tipos de problema son un problema maestro y un subproblema. En cada iteración del método se resuelve un nuevo subproblema, cuya solución determina una nueva restricción para agregar al problema maestro.

La descomposición de Benders se suele utilizar en programación estocástica, por ejemplo, cuando se tiene un vector de variables aleatoria para la cual se tiene distintos valores (escenarios) posibles, y otro vector de variables deterministas, cuyo valor óptimo se vea afectado por los distintos escenarios posibles de las variables aleatorias. Siguiendo esta misma línea, es un método que se ocupa ampliamente para resolver problemas de optimización multinivel (Vicente & Calamai, 1994).

3.3.1.2. Dantzing-Wolfe

El método de descomposición de Dantzig & Wolfe (1961), es un método de generación de columnas para problemas lineales de gran escala, aprovechando el hecho de que en una solución óptima, muchas variables suelen tomar valores nulos, de modo que, si sólo se selecciona un subgrupo de variables o columnas en un comienzo y se siguen agregando iterativamente de manera inteligente, se puede llegar a la misma solución en menores tiempos, de manera general. Al igual que en el método anterior, existe un problema maestro, el cual resuelve el problema con todas las restricciones, pero sólo teniendo en cuenta un subconjunto de variables, y utiliza distintos subproblemas para escoger nuevas soluciones con nuevas variables para entrar a la base de la solución, si es que estas mejoran la función objetivo del problema. Dada su forma, este algoritmo es útil para problemas con una gran cantidad de restricciones, en donde no se requiere una gran cantidad de variables no nulas en la solución óptima, similar a lo que se requiere en el método de selección de atributos. Debido a esto, el método

propuesto en este escrito presenta grandes similitudes con este método de descomposición.

3.3.2. Métodos de descomposición de problemas de optimización no lineal

Existen métodos de descomposición muy similares a los métodos de descomposición de problemas lineales. Es más, el mismo método de descomposición de Benders ha sido extendido para resolver problemas no lineales (Karbowksi, 2021). Además de este método, también existen alternativas como los métodos de descomposición que hacen uso de la relajación lagrangiana de un problema de optimización de gran escala, como los revisados en el libro de Nowak (2005). Como nueva alternativa para distintos tipos de problemas de optimización no lineal, se describe en la subsección 3.4.3 un nuevo método de generación de columnas y relajación lagrangiana para problemas de optimización de gran escala con restricciones cónicas.

3.4. Estado del arte

3.4.1. Métodos de selección de atributos con optimización exacta

En esta sección se detallan algunos de los métodos de selección de atributos con optimización exacta más utilizados. Estos métodos siguen una lógica similar, y en algunos de ellos se utilizan las versiones con relajación lagrangiana del problema en vez del problema de optimización con restricciones.

3.4.1.1. LASSO

El primero de los métodos a revisar es el, ya mencionado, LASSO propuesto por Tibshirani (1996), el cual sigue siendo una de las técnicas más utilizadas para regularización y selección de variables en problemas de regresión. El problema de optimización originalmente descrito busca minimizar el error cuadrático al igual que en Mínimos Cuadrados Ordinarios, pero

restringiendo los coeficientes por un parámetro previamente establecido. Esto es, dada una matriz $X \in \mathbb{R}^{n \times m}$ de m atributos y n observaciones, un vector $y \in \mathbb{R}^n$ de n variables independientes a predecir, y un vector de coeficientes a estimar $\beta \in \mathbb{R}^m$, LASSO resuelve el problema

$$\begin{aligned} \min_{\beta \in \mathbb{R}^m} \quad & \|y - X\beta\|_2^2 \\ \text{s. a} \quad & \|\beta\|_1 \leq t, \end{aligned} \tag{3.13}$$

donde $\|\cdot\|_p$ es la norma vectorial ℓ^p : $\|\beta\|_p = \left(\sum_{j=1}^m |\beta_j|^p\right)^{1/p}$.

Una forma alternativa, igualmente utilizada, del método de LASSO es resolver un problema equivalente, con un parámetro de peso λ a la norma ℓ^1 de los coeficientes de la forma

$$\min_{\beta \in \mathbb{R}^m} \quad \|y - X\beta\|_2^2 + \lambda \|\beta\|_1. \tag{3.14}$$

Este problema deriva directamente de la relajación lagrangiana de (3.13), al fijar el valor de los coeficientes t y λ .

3.4.1.2. Elastic Net

Con una formulación similar, inspirada tanto en LASSO como en la regresión Ridge, Zou & Hastie (2005) proponen Elastic Net, la cual consiste en una optimización irrestricta con la misma forma de 3.14, con un término adicional de castigo para la norma euclidiana ℓ^2 al cuadrado del vector de coeficientes β ; es decir, resuelve

$$\min_{\beta \in \mathbb{R}^m} \quad \|y - X\beta\|_2^2 + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2. \tag{3.15}$$

El término de castigo asociado a la norma euclidiana tiene el rol de disminuir los valores de los coeficientes, con énfasis en los de mayor tamaño, ya que castiga el cuadrado del valor de cada coeficiente.

3.4.2. Modelos lineales y selección de atributos con optimización cónica

Existen diversos acercamientos a los modelos lineales, de distinto tipo, con restricciones cónicas en la actualidad. Bertsimas et al. (2016) propone una formulación entera mixta para el *Best Subset Selection Problem*, en la cual se minimiza el error cuadrático de un modelo lineal (como en mínimos cuadrados ordinarios), pero se agregan restricciones con variables binarias para elección de coeficientes del modelo lineal, fijando un máximo número de ellos a escoger, como en la propuesta original de LASSO. En el mismo artículo proponen distintas versiones cónicas similares a las de dicho problema, para obtener cotas inferiores del modelo original. En el Capítulo 4 se revisa este modelo como punto de partida para los problemas con restricciones cónicas a utilizar.

Con restricciones del mismo tipo que el modelo entero antes mencionado, Kucukyavuz et al. (2020) propone un modelo entero mixto cónico de segundo orden (MISOCP), modificando las restricciones que acotan a los coeficientes del modelo que proponen con una propiedad que las permite escribir como conos de segundo orden. Además, incorporan un parámetro de regularización en la función objetivo, como en la relajación del modelo LASSO, y otro de castigo por cada variable extra que se agrega al modelo. Esta estrategia también se revisa en la metodología expuesta en el Capítulo 4.

Por último, Schwendinger et al. (2022) proponen un paquete para resolver distintos tipos de modelos lineales (Modelos Lineales Holísticos Generalizados), con una gran variedad de restricciones cónicas posibles, como conos de segundo orden y conos exponenciales. Estos modelos se alejan de la propuesta de estudio de este trabajo, por lo que no son revisados.

3.4.3. Método de descomposición para problemas de optimización cónica

Chicoisne (2023) propone un nuevo método de descomposición para problemas no lineales de gran escala de la forma

$$\begin{aligned}
 (P(\mathcal{X})) \quad \omega(\mathcal{X}) = \min_{x,y} \quad & f(x, y) \\
 \text{s. a} \quad & x \in \mathcal{X}, \\
 & -g(x, y) \in \mathcal{C},
 \end{aligned} \tag{3.16}$$

donde $x \in \mathcal{X}$ son las variables principales del problema, con $\mathcal{X}$ un conjunto de alta dimensionalidad, el vector y es una variable auxiliar, $\mathcal{C}$ es un cono en algún espacio euclidiano y f es alguna función de un espacio vectorial a valores escalares. El supuesto inicial del método de descomposición que propone es que la dificultad del problema $(P(\mathcal{X}))$ deriva de dos fuentes; en primer lugar, de la existencia de las restricciones cónicas $-g(x, y) \in \mathcal{C}$ y, además, de la alta dimensionalidad de $\mathcal{X}$; es decir, se tiene un problema que, o bien es posible de resolver de manera eficiente en un subconjunto $\mathcal{S} \subseteq \mathcal{X}$ de baja dimensionalidad, o bien es posible de resolver eficientemente con la eliminación de las restricciones cónicas $-g(x, y) \in \mathcal{C}$.

Con la idea anterior, se pueden generar dos tipos de problema alternativos, el primero siendo $(P(\mathcal{S}))$, el cual tiene la misma forma de (3.16), pero con $x \in \mathcal{S}$, el cual, al ser un problema de optimización en un subconjunto de la región factible de $(P(\mathcal{X}))$, necesariamente entrega un valor objetivo óptimo mayor o igual al de este; es decir, se cumple que $\omega(\mathcal{X}) \leq \omega(\mathcal{S})$. Por otro lado, el segundo tipo de problema se puede generar con la relajación lagrangiana de las restricciones cónicas, de la forma

$$\begin{aligned}
 (L(\mathcal{X}, \lambda)) \quad \omega(\mathcal{X}, \lambda) = \min_{x,y} \quad & f(x, y) + \langle \lambda, g(x, y) \rangle \\
 \text{s. a} \quad & x \in \mathcal{X},
 \end{aligned} \tag{3.17}$$

con $\lambda \in \mathcal{C}^*$, donde $\mathcal{C}^*$ es el cono dual de $\mathcal{C}$, definido como $\mathcal{C} := \{u : \langle u, v \rangle \geq 0, \forall v \in C\}$; es decir, para x, y factibles en $(P(\mathcal{X}))$ se cumple que $\langle \lambda, g(x, y) \rangle \leq 0, \forall \lambda \in \mathcal{C}^*$. Sigue que, como $\omega(\mathcal{X}, \lambda)$ es el valor óptimo obtenido de la relajación al minimizar sobre x, y , en particular, este valor será menor o igual que el valor objetivo óptimo de $(P(\mathcal{X}))$; es decir, $\omega(\mathcal{X}, \lambda) \leq \omega(\mathcal{X})$, $\forall \lambda \in \mathcal{C}^*$. Con esto se tienen dos cotas, una inferior y otra superior, para el problema (3.16), los cuales son sencillos de resolver si se cumplen los supuestos iniciales de este problema.

Se puede generar entonces un algoritmo iterativo que tome ventaja de estos dos problemas que acotan a $(P(\mathcal{X}))$, y genere distintos subconjuntos $\mathcal{S}^k$, los cuales, a su vez, deriven desde nuevas soluciones (no necesariamente factibles en el problema original) entregadas por $(L(\lambda, \mathcal{X}))$, como el Algoritmo 1 que propone Chicoisne (2023).

Algoritmo 1: CG

Datos: Un problema $P(\mathcal{X})$

Resultado: Una solución óptima de $P(\mathcal{X})$

```

1 Definir  $\lambda^0 = 0$ ,  $\mathcal{S}^1 \subseteq \mathcal{X}$  que contenga al menos una solución factible de  $P(\mathcal{X})$ , y  $k = 1$ ;
2 mientras True hacer
3     Resolver  $P(\mathcal{S}^k)$ . Sea  $(x^k, y^k)$  solución óptima ;
4     Sea  $\lambda^k$  un vector dual asociado a las restricciones  $-g(x, y) \in \mathcal{C}$  ;
5     si  $\lambda^k = \lambda^{k-1}$  entonces
6         devolver  $(x^k, y^k)$  ;
7     Resolver  $L(\mathcal{X}, \lambda^k)$ . Sea  $(\bar{x}^k, \bar{y}^k)$  solución óptima ;
8     si  $\bar{x}^k \in \mathcal{S}^k$  entonces
9         devolver  $(x^k, y^k)$  ;
10    Construir un conjunto  $\mathcal{S}^{k+1} \subseteq \mathcal{X}$  que contenga a  $\bar{x}^k$ ;
11     $k \leftarrow k + 1$  ;

```

Capítulo 4

Metodología

4.1. Modelos de optimización para la selección de atributos

Para las siguientes subsecciones, es necesario definir distintos tipos de notación. En primer lugar, para res presentar conjuntos de datos con n observaciones y $m \gg 1$ atributos o columnas, se utiliza

$y \in \mathbb{R}^n$: Vector de observaciones a predecir o de variables dependientes del modelo lineal.

$X \in \mathbb{R}^{n \times m}$: Matriz con distintas observaciones en sus filas y atributos en sus columnas, o matriz de variables independientes del modelo lineal.

Si en un modelo no se explicita el conjunto al que pertenece alguna variable x , se asume que esta pertenece a $\mathbb{R}^q$, con q algún escalar coherente con las operaciones aplicadas a dicha variable. En general, se utiliza en todos los modelos la variable $\beta \in \mathbb{R}^m$ para representar a los coeficientes asociados a cada atributo del modelo lineal en cuestión.

Se utiliza un escalar de gran tamaño $M \gg 1$, o lo suficientemente grande, en restricciones que requieran cotas para las variables del modelo en ciertos escenarios, mientras que, en otros, no requieran dicha cota.

En cuanto a la notación para los vectores utilizados, se tendrá que $x = \begin{pmatrix} x_1 \\ \vdots \\ x_q \end{pmatrix} = (x_1, \dots, x_q) \in \mathbb{R}^q$; es decir, los vectores siempre son vectores columna a menos que se explicita lo contrario. Para representar a vectores filas se utiliza el apóstrofe para representar el vector traspuesto de un vector columna de la forma $x' = \begin{pmatrix} x_1 & \dots & x_q \end{pmatrix} \in \mathbb{R}^{1 \times q}$. Por consecuencia, el producto interno entre dos vectores x e y en un espacio euclidiano puede ser escrito como $\langle x, y \rangle = x'y = \sum_{i=1}^q x_i y_i$.

4.1.1. Modelo basal: Mixed Integer Quadratic Program (MIQP)

Para sentar las bases de los modelos presentados en las subsecciones siguientes, se vuelve a revisar el problema cuadrático mixto propuesto por Bertsimas et al. (2016), mencionado en la 3.4.2. En este modelo, se escoge el mejor subconjunto de atributos, restringiendo la cantidad de coeficientes $\beta_i \neq 0$ a un máximo de k posibles en la solución final, de la forma

$$\min_{\beta, z} \|y - X\beta\|_2^2 \quad (4.1a)$$

$$\text{s.a} \quad -Mz_i \leq \beta_i \leq Mz_i, \quad i = 1, \dots, m \quad (4.1b)$$

$$\sum_{i=1}^m z_i \leq k \quad (4.1c)$$

$$z \in \{0, 1\}^m. \quad (4.1d)$$

Notando que (4.1c) es la misma restricción original de LASSO (3.13), esta puede relajarse de la misma manera que en este modelo, por lo que el problema de escoger el mejor subconjunto puede ser reescrito de manera equivalente como

$$\min_{\beta, z} \|y - X\beta\|_2^2 + \tau \|z\|_1 \quad (4.2a)$$

$$\text{s.a} \quad -Mz_i \leq \beta_i \leq Mz_i, \quad i = 1, \dots, m \quad (4.2b)$$

$$z \in \{0, 1\}^m. \quad (4.2c)$$

La equivalencia entre ambos problemas depende de los valores de los parámetros k y τ , de la misma manera que con las dos alternativas de LASSO.

Dada la positividad de las componentes del vector z , para facilitar la lectura, en los modelos que siguen a continuación se escribirá la norma ℓ^1 de este vector en forma de sumatoria.

Al igual que en el MISOCP de Kucukyavuz et al. (2020), también mencionado en la subsección 3.4.2, las dos cotas acotando a los coeficientes en (4.2b) pueden ser reescritas en forma cuadrática, en una sola restricción, quedando así el problema (4.2) de la forma

$$\min_{\beta, z} \quad \|y - X\beta\|_2^2 + \tau \sum_{i=1}^m z_i \quad (4.3a)$$

$$\text{s.a} \quad \beta_i^2 \leq M^2 z_i, \quad i = 1, \dots, m \quad (4.3b)$$

$$z \in \{0, 1\}^m, \quad (4.3c)$$

donde aquí se aprovecha que z_i son variables binarias, por lo que su cuadrado es la misma variable. Un aspecto a considerar con respecto a al parámetro $M \gg 1$ es que no existe un valor mínimo que deba tomar para tener resultados factibles como en otro tipo de problemas, ya que siempre existen valores de β_i , en particular $\beta_i = 0$, para cualquier valor de M . Dicho esto, de una manera ligeramente similar al MISOCP antes mencionado, este parámetro puede ser una nueva variable en vez de un parámetro, a la cual también se le asigne alguna penalización κ , para acotar de esta manera los valores de los coeficientes b_i , con lo que se puede plantear un modelo alternativo de la forma

$$\min_{\beta, z, u} \quad \|y - X\beta\|_2^2 + \tau \sum_{i=1}^m z_i + \kappa \sum_{i=1}^m u_i \quad (4.4a)$$

$$\text{s.a} \quad \beta_i^2 \leq u_i z_i, \quad i = 1, \dots, m \quad (4.4b)$$

$$u_i \geq 0, \quad i = 1, \dots, m \quad (4.4c)$$

$$z \in \{0, 1\}^m. \quad (4.4d)$$

4.1.2. Modelo relajado: Quadratic Program (QP)

Dado el problema cuadrático entero mixto MIQP (4.4), es posible establecer una versión relajada de dicho problema; es decir, quitar la restricción entera sobre el vector de variables z de la forma

$$\min_{\beta, z, u} \quad \|y - X\beta\|_2^2 + \tau \sum_{i=1}^m z_i + \kappa \sum_{i=1}^m u_i \quad (4.5a)$$

$$\text{s.a} \quad \beta_i^2 \leq u_i z_i, \quad i = 1, \dots, m \quad (4.5b)$$

$$u_i \geq 0, \quad i = 1, \dots, m \quad (4.5c)$$

$$z_i \geq 0, \quad i = 1, \dots, m. \quad (4.5d)$$

Este problema sigue manteniendo la idea de acotar las magnitudes de los coeficientes β , e intentar que tomen valores lo menor posible con los parámetros de castigo τ y κ . La única diferencia con el modelo con variable binaria es que ya no es un problema de selección del mejor subconjunto como el MIQP original (4.1).

Observando con mayor detalle el problema relajado, es claro que si $\tau = \kappa$, entonces el problema es simétrico con respecto a z y u , dado que tienen las mismas restricciones y términos en la función objetivo. Es más, en Proposición 1 se establece una equivalencia con respecto a los problemas en donde esta condición se cumple.

Proposición 1 $\forall \tau, \kappa \in \mathbb{R}_{++}$, parámetros del problema relajado (4.5), existe un problema equivalente con la misma estructura, pero con otros parámetros $\tilde{\tau}$ y $\tilde{\kappa}$, tales que $\tilde{\tau} = \tilde{\kappa} = \sqrt{\tau\kappa}$.

DEMOSTRACIÓN. Basta notar que se puede escribir $\kappa = \alpha^2 \tau$, con $\alpha > 0$ definido por la misma ecuación, en el problema (4.5). Luego, el problema en cuestión puede ser escrito como

$$\begin{aligned} (P1) \quad \min_{\beta, z, u} \quad & \|y - X\beta\|_2^2 + \tau \sum_{i=1}^m z_i + \alpha^2 \tau \sum_{i=1}^m u_i \\ \text{s.a} \quad & \beta_i^2 \leq u_i z_i, \quad i = 1, \dots, m \\ & u_i \geq 0, \quad i = 1, \dots, m \\ & z_i \geq 0, \quad i = 1, \dots, m. \end{aligned}$$

El candidato a problema equivalente de la misma forma es el problema

$$\begin{aligned}
(P2) \quad & \min_{\beta, z, u} \quad \|y - X\beta\|_2^2 + \alpha\tau \sum_{i=1}^m z_i + \alpha\tau \sum_{i=1}^m u_i \\
& \text{s.a} \quad \beta_i^2 \leq u_i z_i, & i = 1, \dots, m \\
& u_i \geq 0, & i = 1, \dots, m \\
& z_i \geq 0, & i = 1, \dots, m.
\end{aligned}$$

Es sencillo notar que un punto factible de $(P1)$ es también un punto factible de $(P2)$, y viceversa, ya que ambos problemas tienen la misma región factible; solo cambia la función objetivo.

Sean (β^*, z^*, u^*) y $(\tilde{\beta}^*, \tilde{z}^*, \tilde{u}^*)$ soluciones óptimas de $(P1)$ y $(P2)$ respectivamente. El mínimo valor posible de la función objetivo de $(P1)$ se alcanza en el primero de estos vectores, y lo mismo para $(P2)$ con el segundo vector. Luego, tomando los vectores $\bar{u}^* = \alpha u^*$ y $\bar{z}^* = \frac{1}{\alpha} z^*$, se puede escribir la función objetivo de $(P1)$ evaluada en su punto óptimo como

$$\|y - X\beta^*\|_2^2 + \tau \sum_{i=1}^m z_i^* + \alpha^2 \tau \sum_{i=1}^m u_i^* = \|y - X\beta^*\|_2^2 + \alpha\tau \sum_{i=1}^m \bar{z}_i^* + \alpha\tau \sum_{i=1}^m \bar{u}_i^*.$$

Sigue que $(\beta^*, \bar{z}^*, \bar{u}^*)$ es, además, un punto factible de $(P2)$, ya que $\beta_i^* \leq u_i^* z_i^* = \bar{u}_i^* \bar{z}_i^*$, para toda componente de estos vectores, y $\bar{z}^*, \bar{u}^*$ mantienen la positividad de sus componentes al ser multiplicación de valores positivos. Entonces, al ser punto factible del segundo problema, se cumple la relación

$$\begin{aligned}
\|y - X\tilde{\beta}^*\|_2^2 + \alpha\tau \sum_{i=1}^m \tilde{z}_i^* + \alpha\tau \sum_{i=1}^m \tilde{u}_i^* & \leq \|y - X\beta^*\|_2^2 + \alpha\tau \sum_{i=1}^m \bar{z}_i^* + \alpha\tau \sum_{i=1}^m \bar{u}_i^* \\
& = \|y - X\beta^*\|_2^2 + \tau \sum_{i=1}^m z_i^* + \alpha^2 \tau \sum_{i=1}^m u_i^*
\end{aligned}$$

con el punto óptimo $(\tilde{\beta}^*, \tilde{z}^*, \tilde{u}^*)$; es decir, el valor óptimo de la función objetivo de $(P2)$ es una cota inferior del valor objetivo de $(P1)$.

De manera análoga a lo anterior, se pueden tomar los vectores $\hat{u}^* = \frac{1}{\alpha}\tilde{u}^*$ y $\hat{z}^* = \alpha\tilde{z}^*$, para reescribir la función objetivo de $(P2)$ como

$$\|y - X\tilde{\beta}^*\|_2^2 + \alpha\tau \sum_{i=1}^m \tilde{z}_i^* + \alpha\tau \sum_{i=1}^m \tilde{u}_i^* = \|y - X\tilde{\beta}^*\|_2^2 + \tau \sum_{i=1}^m \hat{z}_i^* + \alpha^2\tau \sum_{i=1}^m \hat{u}_i^*.$$

Nuevamente, es fácil ver que el punto $(\tilde{\beta}^*, \hat{z}^*, \hat{u}^*)$ es factible en $(P1)$ con la misma justificación anterior. Dicho esto, se cumple la desigualdad

$$\begin{aligned} \|y - X\beta^*\|_2^2 + \tau \sum_{i=1}^m z_i^* + \alpha^2\tau \sum_{i=1}^m u_i^* &\leq \|y - X\tilde{\beta}^*\|_2^2 + \tau \sum_{i=1}^m \hat{z}_i^* + \alpha^2\tau \sum_{i=1}^m \hat{u}_i^* \\ &= \|y - X\tilde{\beta}^*\|_2^2 + \alpha\tau \sum_{i=1}^m \tilde{z}_i^* + \alpha\tau \sum_{i=1}^m \tilde{u}_i^* \end{aligned}$$

con el punto óptimo (β^*, z^*, u^*) de este problema; por lo tanto, el valor óptimo de la función objetivo de $(P1)$ es una cota inferior del valor objetivo de $(P2)$. Como el valor objetivo de $(P1)$ acota de manera inferior y superior al valor objetivo de $(P2)$, entonces ambos valores son iguales, por lo que se cumple que

$$\|y - X\beta^*\|_2^2 + \tau \sum_{i=1}^m z_i^* + \alpha^2\tau \sum_{i=1}^m u_i^* = \|y - X\tilde{\beta}^*\|_2^2 + \alpha\tau \sum_{i=1}^m \tilde{z}_i^* + \alpha\tau \sum_{i=1}^m \tilde{u}_i^*.$$

En conclusión, los problemas $(P1)$ y $(P2)$ son problemas equivalentes. Como los valores de τ y κ son arbitrarios en $\mathbb{R}_{++}$, entonces se cumple que $\forall \tau, \kappa \in \mathbb{R}_{++}$, parámetros del problema (4.5), existe un problema equivalente, de la misma forma, con otros parámetros $\tilde{\tau}$ y $\tilde{\kappa}$, tales que $\tilde{\tau} = \tilde{\kappa}$.

Es directo notar a partir del resultado anterior que $(\tilde{\beta}^*, \hat{z}^*, \hat{u}^*)$ es punto óptimo de $(P1)$ y que $(\beta^*, \bar{z}^*, \bar{u}^*)$ es punto óptimo de $(P2)$, por lo que se puede obtener la misma solución para los coeficientes β_i en ambos problemas. $\square$

El resultado de Proposición 1 no toma en cuenta los aspectos computacionales que podrían diferenciar a los problemas equivalentes con pesos distintos de los con parámetros iguales, por lo que, en lo que sigue, se siguen utilizando ambos parámetros de manera independiente.

Otro punto importante a notar es que el problema acota a los coeficientes del problema (4.5) de manera similar a la versión relajada de LASSO (3.14), con un castigo de primer grado para las magnitudes de las componentes de β . Se establece la relación entre ambos problemas en el siguiente Proposición.

Proposición 2 $\forall \tau, \kappa \in \mathbb{R}_{++}$, parámetros del problema relajado (4.5), existe un problema en equivalente de la versión relajada de LASSO (3.14) con parámetro de penalización $\lambda = 2\sqrt{\tau\kappa}$.

DEMOSTRACIÓN. Basta tomar el problema equivalente de (4.5), con los parámetros $\tilde{\tau} = \tilde{\kappa} = \sqrt{\tau\kappa}$, utilizar la simetría del problema con respecto a z_i y u_i , para quedar con una función objetivo $\|y - X\beta\|_2^2 + 2\sqrt{\tau\kappa} \sum_{i=1}^m z_i$. Luego, notar que en el óptimo del problema se cumple la igualdad $|\beta_i| = z_i, \forall i \in \{1, \dots, m\}$, por lo que se puede escribir el problema equivalente con la función objetivo $\|y - X\beta\|_2^2 + 2\sqrt{\tau\kappa} \sum_{i=1}^m |\beta_i|$, lo que es justamente la versión lagrangiana de LASSO con penalización $\lambda = 2\sqrt{\tau\kappa}$. $\square$

4.1.3. Modelo cónico: Second Order Cone Program (SOCP)

Nuevamente, tal y como lo describen para el MISOCP de Kucukyavuz et al. (2020), se puede utilizar el resultado

$$a^2 \leq bc \iff \left\| \begin{pmatrix} b - c \\ 2a \end{pmatrix} \right\|_2 \leq b + c, \quad \forall a \in \mathbb{R}, \quad b, c \in \mathbb{R}_+, \quad (4.8)$$

en las restricciones (4.5b) el modelo relajado, para obtener un modelo con restricciones cónicas de segundo orden (SOC), sobre las cuales poder aplicar el método de descomposición de problemas cónicos descrito en la subsección 3.4.3. El problema cónico de segundo orden (SOCP) queda entonces como

$$\min_{\beta, z, u} \quad \|y - X\beta\|_2^2 + \tau \sum_{i=1}^m z_i + \kappa \sum_{i=1}^m u_i \quad (4.9a)$$

$$\text{s.a} \quad \left\| \begin{pmatrix} u_i - z_i \\ 2\beta_i \end{pmatrix} \right\|_2 \leq u_i + z_i, \quad i = 1, \dots, m \quad (4.9b)$$

$$u_i \geq 0, \quad i = 1, \dots, m \quad (4.9c)$$

$$z_i \geq 0, \quad i = 1, \dots, m. \quad (4.9d)$$

Se puede aprovechar la estructura del problema para incluir aún más posibilidades en cuanto a la relajación de restricciones cónicas para el método de descomposición de la subsección 3.4.3, acotando el término de la función objetivo de errores cuadráticos por una nueva variable $\xi \in \mathbb{R}$ que alcance la igualdad en el óptimo; es decir, tomar $\|y - X\beta\|_2 \leq \xi$, y minimizar la nueva variable de la forma

$$\min_{\beta, z, u, \xi} \quad \xi^2 + \tau \sum_{i=1}^m z_i + \kappa \sum_{i=1}^m u_i \quad (4.10a)$$

$$\text{s.a} \quad \|y - X\beta\|_2 \leq \xi \quad (4.10b)$$

$$\left\| \begin{pmatrix} u_i - z_i \\ 2\beta_i \end{pmatrix} \right\|_2 \leq u_i + z_i, \quad i = 1, \dots, m \quad (4.10c)$$

$$u_i \geq 0, \quad i = 1, \dots, m \quad (4.10d)$$

$$z_i \geq 0, \quad i = 1, \dots, m. \quad (4.10e)$$

donde, nuevamente, se tiene una nueva restricción cónica de segundo orden, la cual también se puede relajar en el método de descomposición, como se expone en las subsecciones siguientes.

4.2. Método de descomposición para el modelo cónico de segundo orden

Recapitulando lo visto en la subsección 3.4.3, los problemas sobre los cuales se aplica el método de descomposición cónico de Chicoisne (2023) son de la forma

$$\min_{x,y} f(x,y) \quad (4.11)$$

$$\begin{aligned} \text{s. a} \quad & x \in \mathcal{X}, \\ & -g(x,y) \in \mathcal{C}, \end{aligned}$$

donde $\mathcal{C}$ es un conjunto de restricciones cónicas difíciles de resolver. En el caso de (4.10), este conjunto puede ser interpretando de distintas maneras, ya que se puede tomar a cualquiera de las restricciones de cono de segundo orden como candidata para relajación, o incluso se pueden tomar distintas intersecciones de ellas, dado que la intersección de conos también es un cono. Para explicitar aún más las posibilidades de conjuntos cónicos que se pueden relajar, se puede reescribir el problema cónico de segundo orden (4.10) de la subsección anterior de la forma

$$\min_{\beta,z,u,\xi} \xi^2 + \tau \sum_{i=1}^m z_i + \kappa \sum_{i=1}^m u_i \quad (4.12a)$$

$$\text{s.a} \quad \begin{pmatrix} y - X\beta \\ \xi \end{pmatrix} \in \mathcal{L}_{n+1} \quad (4.12b)$$

$$\begin{pmatrix} u_i - z_i \\ 2\beta_i \\ u_i + z_i \end{pmatrix} \in \mathcal{L}_3, \quad i = 1, \dots, m \quad (4.12c)$$

$$u \in \mathbb{R}_+^m, \quad (4.12d)$$

$$z \in \mathbb{R}_+^m, \quad (4.12e)$$

donde $\mathcal{L}_{k+1} = \{(x, y) \in \mathbb{R}^{k+1} : \|x\|_2 \leq y\}$ es un cono de segundo orden de dimensión $k+1$, y $\mathbb{R}_+^m$ es el cono que contiene a todos los vectores en $\mathbb{R}^m$ con sus componentes no negativas.

En cuanto a los supuestos generales del método de descomposición descrito en la subsección 3.4.3, se tendrán dos consideraciones para este caso particular:

1. En cuanto a la alta dimensionalidad de las variables $\mathcal{X}$, las únicas variables que agregan complejidad en este sentido son $\beta, z, u \in \mathbb{R}^m$, ya que ξ agrega sólo una dimensión extra,

independiente del valor de m . Dicho esto, el método descrito en las subsecciones anteriores sólo se complejiza si es que se consideran distintas soluciones para esta variable, además de que sólo se trata de una variable auxiliar que se define completamente con y , X y β en el punto óptimo, esta es utilizada siempre como variable auxiliar en todo lo que sigue.

2. Por otro lado, en cuanto a la complejidad de las restricciones cónicas del problema cónico (4.12), dado que todas las restricciones del problema son de forma cónica, no es claro si todas las restricciones complejizan el problema o si son sólo ciertas restricciones las complejas de resolver; es decir, se pueden tomar distintas combinaciones de restricciones cónicas a relajar (distintos $\mathcal{X}$ y $\mathcal{C}$). Sin embargo, las restricciones de positividad son conocidas en múltiples problemas y no son candidatas a restricciones complejas, dada su naturaleza *sparse* (sólo hay una variable en cada una de estas restricciones).

4.2.1. Algoritmo de descomposición para el modelo cónico de segundo orden

En términos generales, y considerando lo mencionado en la subsección anterior, el Algoritmo 1 presentado en la subsección 3.4.3 puede ser reescrito de manera adaptada a la forma del problema cónico (4.12). De manera genérica, el algoritmo es de la forma que se aprecia en el Algoritmo 2. En este, las soluciones óptimas del problema maestro $P(\mathcal{S}^k)$ son escritas como x^k , mientras que las soluciones de la relajación $L(\mathcal{X}, \lambda^k)$ son escritas de la forma $\bar{x}^k$.

4.2.2. Construcción de la región factible $\mathcal{S}^k$

El primer elemento a considerar en el método de descomposición es la construcción de los subconjuntos $\mathcal{S}^k \subseteq \mathcal{X}$; en otras palabras, la región factible del problema maestro. Estos deben ser tales que las instancias $P(\mathcal{S}^k)$ del problema maestro sean posibles de resolver de manera más eficiente que $P(\mathcal{S}^k)$, mientras que en cada iteración del método vayan incorporando soluciones óptimas de la relajación lagrangiana de la línea 7 del algoritmo. Teniendo esto en cuenta, se hace natural pensar en $\mathcal{S}^k$ como algún tipo de combinación de las soluciones

Algoritmo 2: CG genérico para SOCP

Datos: Una instancia del problema (4.12)

Resultado: Una solución óptima de dicho problema

```
1 Definir  $\lambda^0 = 0$ ,  $\mathcal{S}^1 \subseteq \mathcal{X}$  que contenga al menos una solución factible de  $P(\mathcal{X})$  y  $k = 1$ ;  
2 mientras True hacer  
3     Resolver  $P(\mathcal{S}^k)$ . Sea  $(\beta^k, z^k, u^k; \xi^k)$  solución óptima ;  
4     Sea  $\lambda^k$  un vector dual asociado a las restricciones  $-g(\beta, z, u; \xi) \in C$  ;  
5     si  $\lambda^k = \lambda^{k-1}$  entonces  
6         devolver  $(\beta^k, z^k, u^k; \xi^k)$  ;  
7     Resolver  $L(\mathcal{X}, \lambda^k)$ . Sea  $(\bar{\beta}^k, \bar{z}^k, \bar{u}^k; \bar{\xi}^k)$  solución óptima ;  
8     si  $(\bar{\beta}^k, \bar{z}^k, \bar{u}^k) \in \mathcal{S}^k$  entonces  
9         devolver  $(\beta^k, z^k, u^k; \xi^k)$  ;  
10    Construir  $\mathcal{S}^{k+1} \subseteq \mathcal{X}$  tal que contenga a  $(\bar{\beta}^k, \bar{z}^k, \bar{u}^k)$  ;  
11     $k \leftarrow k + 1$  ;
```

obtenidas en las $k - 1$ iteraciones anteriores. Chicoisne (2023) revisa esta misma idea con distintos tipos de combinaciones, entre las cuales están la combinación convexa, cónica y lineal.

Para el método de descomposición del problema (4.12) se tomarán como opciones de construcción de $\mathcal{S}^k$ estas tres combinaciones de soluciones y, además, su combinación afín. En cada una de estas alternativas existirá un conjunto inicial $\mathcal{S}^1$, el cual contendrá un número definido v_0 (parámetro) de puntos factibles iniciales de $P(\mathcal{X})$, los que se denotarán como las soluciones $\{\bar{x}^s\}_{s=1}^{v_0} = \{(\bar{\beta}^s, \bar{z}^s, \bar{u}^s)\}_{s=1}^{v_0}$. El problema $P(\mathcal{S}^k)$ buscará encontrar los ponderadores óptimos de este problema $\pi \in \mathbb{R}^{v_0+k-1}$ para las v_0 soluciones iniciales y $k - 1$ soluciones obtenidas en cada iteración $\{\bar{x}^s\}_{s=1}^{v_0+k-1} = \{(\bar{\beta}^s, \bar{z}^s, \bar{u}^s)\}_{s=1}^{v_0+k-1}$.

1. Combinación convexa:

$$\mathcal{S}^k := \left\{ x \in \mathcal{X} : x = \sum_{s=1}^{v_0+k-1} \pi_s \bar{x}^s, \quad \pi \in \mathbb{R}_+^{v_0+k-1}, \quad \sum_{s=1}^{v_0+k-1} \pi_s = 1 \right\} = \mathcal{X} \cap \text{conv}(\{\bar{x}^s\}_{s=1}^{v_0+k-1})$$

2. Combinación afín:

$$\mathcal{S}^k := \left\{ x \in \mathcal{X} : x = \sum_{s=1}^{v_0+k-1} \pi_s \bar{x}^s, \quad \pi \in \mathbb{R}^{v_0+k-1}, \quad \sum_{s=1}^{v_0+k-1} \pi_s = 1 \right\} = \mathcal{X} \cap \text{aff}(\{\bar{x}^s\}_{s=1}^{v_0+k-1})$$

3. Combinación cónica:

$$\mathcal{S}^k := \left\{ x \in \mathcal{X} : x = \sum_{s=1}^{v_0+k-1} \pi_s \bar{x}^s, \quad \pi \in \mathbb{R}_+^{v_0+k-1} \right\} = \mathcal{X} \cap \text{cone}(\{\bar{x}^s\}_{s=1}^{v_0+k-1})$$

4. Combinación lineal:

$$\mathcal{S}^k := \left\{ x \in \mathcal{X} : x = \sum_{s=1}^{v_0+k-1} \pi_s \bar{x}^s, \quad \pi \in \mathbb{R}^{v_0+k-1} \right\} = \mathcal{X} \cap \text{lin}(\{\bar{x}^s\}_{s=1}^{v_0+k-1})$$

La elección de los puntos factibles iniciales $\{\bar{x}^s\}_{s=1}^{v_0}$ como los elementos que determinan al conjunto $\mathcal{S}^1$ también puede ser de diversas maneras. Sin embargo, por simplicidad, este estudio no se centra en la búsqueda del mejor conjunto inicial. Dicho esto, se proponen algunas alternativas simples para la elección de este conjunto inicial:

1. Elección de los v_0 vectores iniciales factibles $P(\mathcal{X})$ de manera aleatoria dentro de la región factible.
2. Vector solución único constante $\bar{x}^1 = \mathbf{e}$, donde $\mathbf{e}$ es el vector que tiene todas sus componentes iguales a 1.

Se pueden utilizar ambos métodos de elección de conjunto inicial tanto de manera conjunta como separada.

4.2.3. Problema maestro $P(\mathcal{S}^k)$

Dado un conjunto de soluciones $\mathcal{S}^k$ construido con alguna de las alternativas de la subsección anterior, se puede resumir la combinación asociada a cada una de las variables β, z y u como la multiplicación de una matriz de las soluciones de cada una de estas y los ponderadores; es decir, se pueden definir las siguientes matrices

$$\begin{aligned}
\mathbf{B}^k &= \begin{pmatrix} \bar{\beta}_1^1 & \dots & \bar{\beta}_1^{v_0+k-1} \\ \vdots & \ddots & \vdots \\ \bar{\beta}_m^1 & \dots & \bar{\beta}_m^{v_0+k-1} \end{pmatrix} \in \mathbb{R}^{m \times (v_0+k-1)}, \\
\mathbf{U}^k &= \begin{pmatrix} \bar{u}_1^1 & \dots & \bar{u}_1^{v_0+k-1} \\ \vdots & \ddots & \vdots \\ \bar{u}_m^1 & \dots & \bar{u}_m^{v_0+k-1} \end{pmatrix} \in \mathbb{R}^{m \times (v_0+k-1)}, \\
\mathbf{Z}^k &= \begin{pmatrix} \bar{z}_1^1 & \dots & \bar{z}_1^{v_0+k-1} \\ \vdots & \ddots & \vdots \\ \bar{z}_m^1 & \dots & \bar{z}_m^{v_0+k-1} \end{pmatrix} \in \mathbb{R}^{m \times (v_0+k-1)},
\end{aligned}$$

donde $\mathbf{B}_s^k$ representa la s -ésima columna de la matriz $\mathbf{B}^k$, mientras que $\mathbf{b}_i^k$ representa su i -ésima fila, y la misma notación para las otras dos matrices. Con esta notación, se puede definir el problema maestro $P(\mathcal{S}^k)$ del problema cónico (4.12) como

$$\min_{\pi, \xi} \quad \xi^2 + \tau \sum_{i=1}^m \mathbf{z}_i^k \pi + \kappa \sum_{i=1}^m \mathbf{u}_i^k \pi \quad (4.13a)$$

$$\text{s.a.} \quad \begin{pmatrix} y - X\mathbf{B}^k \pi \\ \xi \end{pmatrix} \in \mathcal{L}_{n+1} \quad (4.13b)$$

$$\begin{pmatrix} \mathbf{u}_i^k - \mathbf{z}_i^k \\ 2\mathbf{b}_i^k \\ \mathbf{u}_i^k + \mathbf{z}_i^k \end{pmatrix} \pi \in \mathcal{L}_3 \quad i = 1, \dots, m, \quad (4.13c)$$

$$\pi \in \Pi, \quad (4.13d)$$

donde Π es el conjunto de todas las restricciones extra necesarias sobre los ponderadores para definir a la combinación escogida (positividad o suma igual a uno). Las restricciones de positividad sobre las componentes de $\mathbf{Z}^k \pi$ y $\mathbf{U}^k \pi$ no son necesarias, ya que siempre se obtienen soluciones que cumplen estas restricciones en cada iteración.

4.2.4. Relajación lagrangiana $L(\mathcal{X}, \lambda^k)$

De manera general, luego de resolver una instancia del problema maestro $P(\mathcal{S}^k)$, se obtienen las variables duales λ^k asociadas al óptimo de este problema. A partir de estas soluciones y de la relajación de las restricciones cónicas complejas, se puede construir un problema de optimización de minimización de la forma (3.17). Sin embargo, tal y como se menciona al comienzo de la sección, existen diversas manera de relajar el problema cónico (4.12). Se considerarán entonces tres posibilidades para esta relajación:

1. Relajación de la restricción cónica de segundo orden en $\mathcal{L}_{n+1}$ (4.13b). Para simplificar notación, se denotará a esta restricción como $\mathcal{C}_1$.
2. Relajación de las m restricciones cónicas de segundo orden en $\mathcal{L}_3$ (4.13c). A este conjunto de restricciones se le denotará como $\mathcal{C}_2$.
3. Relajación de las restricciones $\mathcal{C}_1$ y $\mathcal{C}_2$.

Para entender las relajaciones anteriormente descritas, se presenta la relajación lagrangiana de ambos conjuntos de restricciones

$$L(x, \lambda) = \underbrace{\xi^2 + \tau \sum_{i=1}^m z_i + \kappa \sum_{i=1}^m u_i}_{\text{función objetivo}} - \underbrace{\begin{pmatrix} \psi' & \mu \end{pmatrix} \begin{pmatrix} y - X\beta \\ \xi \end{pmatrix}}_{\mathcal{C}_1} - \underbrace{\sum_{i=1}^m \begin{pmatrix} \alpha_i & \gamma_i & \delta_i \end{pmatrix} \begin{pmatrix} u_i - z_i \\ 2\beta_i \\ u_i + z_i \end{pmatrix}}_{\mathcal{C}_2},$$

donde $x = (\beta, z, u, \xi)$ es el vector que representa las variables primales del problema cónico (4.12), $\lambda = (\psi, \mu, \alpha, \gamma, \delta)$ es el vector que representa a todas las variables duales asociadas a las restricciones relajadas y se ocupa el apóstrofe (') para representar el vector (o matriz) traspuesto. Para mantener la naturaleza de cota inferior de esta función al tomar x factibles en el problema cónico, es necesario que los vectores (ψ, μ) y $(\alpha_i, \gamma_i, \delta_i)$, para todo i entre uno y m , pertenezcan a los conos duales de los conos relajados respectivos a cada vector. Sin embargo, los conos de segundo orden de cualquier dimensión q son autoduales; es decir, se cumple que $\mathcal{L}_q^* = \mathcal{L}_q$. Dicho esto, se debe cumplir entonces que

$$\begin{pmatrix} \psi' \\ \mu \end{pmatrix} \in \mathcal{L}_{n+1} \quad \text{y} \quad \begin{pmatrix} \alpha_i \\ \gamma_i \\ \delta_i \end{pmatrix} \in \mathcal{L}_3, \forall i \in \{1, \dots, m\}.$$

No obstante, el método de descomposición entrega un valor fijo λ^k para las variables duales una vez que se resuelve el problema maestro $P(\mathcal{S}^k)$, por lo que no es necesario imponer estas restricciones de naturaleza sobre los valores de λ^k , ya que necesariamente se cumplen al construir el problema dual del problema maestro. La estructura de cada relajación de conos sigue siendo la misma de todos modos.

4.2.4.1. Relajación de $\mathcal{C}_1$

En esta versión, sólo se relaja la restricción en $\mathcal{C}_1$. Esta es un cono de segundo orden contenido en $\mathbb{R}^{n+1}$, y como ya se mencionó, su cono dual es el mismo cono de segundo orden ($\mathcal{L}_{n+1}^* = \mathcal{L}_{n+1}$), por lo que para relajar esta restricción basta tomar los valores óptimo duales (ψ^k, μ^k) obtenidos con el problema maestro $P(\mathcal{S}^k)$ y escribir la relajación lagrangiana asociada a $\mathcal{C}_1$

$$\begin{aligned} L_{\mathcal{C}_1}(x, \lambda^k) &= \xi^2 + \tau \sum_{i=1}^m z_i + \kappa \sum_{i=1}^m u_i - \begin{pmatrix} \psi^{k'} & \mu^k \end{pmatrix} \begin{pmatrix} y - X\beta \\ \xi \end{pmatrix} \\ &= (\xi - \mu^k)\xi + \psi^{k'}X\beta + \tau\mathbf{e}'z + \kappa\mathbf{e}'u - \psi^{k'}y. \end{aligned}$$

A partir de esta función se arma una nueva función objetivo, mientras que el resto de restricciones del problema ($\mathcal{X}_{\overline{\mathcal{C}_1}}$) se mantienen de la misma forma que en el problema cónico, por lo que se define el problema relajado $L(\mathcal{X}_{\overline{\mathcal{C}_1}}, \lambda^k)$ como

$$(L(\mathcal{X}_{\overline{\mathcal{C}}_1}, \lambda^k)) \quad \min_{\beta, z, u, \xi} \quad (\xi - \mu^k)\xi + \psi^{k'} X\beta + \tau \mathbf{e}' z + \kappa \mathbf{e}' u - \psi^{k'} y \quad (4.14a)$$

$$\text{s.a.} \quad \begin{pmatrix} u_i - z_i \\ 2\beta_i \\ u_i + z_i \end{pmatrix} \in \mathcal{L}_3, \quad i = 1, \dots, m, \quad (4.14b)$$

$$u \in \mathbb{R}_+^m, \quad (4.14c)$$

$$z \in \mathbb{R}_+^m, \quad (4.14d)$$

Este problema se puede simplificar en algunos sentidos, ya que la variable ξ es completamente independiente del resto de las variables del problema, además que es tan solo una variable auxiliar del problema original, por lo que, al eliminar la restricción en la que participa, su valor en sí no es de interés. Se puede eliminar entonces el término $(\xi - \mu^k)\xi$ de la función objetivo y seguir obteniendo el mismo resultado, y, en caso de querer recuperar el valor de esta variable basta con notar que la función objetivo es una función convexa e irrestricta con respecto a ella, por lo que se pueden ocupar las condiciones de primer orden con esta variable para obtener el valor que minimiza este término (imponer un punto silla); es decir, se puede imponer

$$\frac{\partial}{\partial \xi} (\xi - \mu^k)\xi = 0 \implies \xi = \frac{\mu^k}{2},$$

ahorrándose de esta manera la resolución del problema en una dimensión extra.

4.2.4.2. Relajación de $\mathcal{C}_2$

De manera análoga a la relajación de la restricción perteneciente a $\mathcal{C}_1$, en este caso se tiene el mismo tipo de cono autodual, y se escribe la relajación a partir de las soluciones óptimas duales $(\alpha^k, \gamma^k, \delta^k)$ obtenidas con el problema maestro $P(\mathcal{S}^k)$ de la forma

$$\begin{aligned}
L_{\mathcal{C}_2}(x, \lambda^k) &= \xi^2 + \tau \sum_{i=1}^m z_i + \kappa \sum_{i=1}^m u_i - \sum_{i=1}^m \begin{pmatrix} \alpha_i^k & \gamma_i^k & \delta_i^k \end{pmatrix} \begin{pmatrix} u_i - z_i \\ 2\beta_i \\ u_i + z_i \end{pmatrix} \\
&= \xi^2 - 2\gamma^{k'}\beta + (\tau\mathbf{e} + \alpha^k - \delta^k)'z + (\kappa\mathbf{e} - \alpha^k - \delta^k)'u.
\end{aligned}$$

Nuevamente, se puede denotar al resto de restricciones del problema como $\mathcal{X}_{\overline{\mathcal{C}_2}}$, con lo que se define el problema relajado $L(\mathcal{X}_{\overline{\mathcal{C}_2}}, \lambda^k)$ como

$$(L(\mathcal{X}_{\overline{\mathcal{C}_2}}, \lambda^k)) \quad \min_{\beta, z, u, \xi} \quad \xi^2 - 2\gamma^{k'}\beta + (\tau\mathbf{e} + \alpha^k - \delta^k)'z + (\kappa\mathbf{e} - \alpha^k - \delta^k)'u \quad (4.15a)$$

$$\text{s.a.} \quad \begin{pmatrix} y - X\beta \\ \xi \end{pmatrix} \in \mathcal{L}_{n+1} \quad (4.15b)$$

$$u \in \mathbb{R}_+^m, \quad (4.15c)$$

$$z \in \mathbb{R}_+^m, \quad (4.15d)$$

4.2.4.3. Relajación de $\mathcal{C}_1$ y $\mathcal{C}_2$

Se presenta la última alternativa de relajación de restricciones cónicas que representan complejidad a la hora de resolver el problema cónico 4.12, la relajación de los conjuntos $\mathcal{C}_1$ y $\mathcal{C}_2$. Las variables duales obtenidas en el problema maestro del método son las mencionadas en las dos alternativas anteriores, lo que implica una relajación lagrangiana de la forma

$$\begin{aligned}
L_{\mathcal{C}_{1,2}}(x, \lambda^k) &= \xi^2 + \tau \sum_{i=1}^m z_i + \kappa \sum_{i=1}^m u_i - \begin{pmatrix} \psi^{k'} & \mu^k \end{pmatrix} \begin{pmatrix} y - X\beta \\ \xi \end{pmatrix} - \sum_{i=1}^m \begin{pmatrix} \alpha_i^k & \gamma_i^k & \delta_i^k \end{pmatrix} \begin{pmatrix} u_i - z_i \\ 2\beta_i \\ u_i + z_i \end{pmatrix} \\
&= (\xi - \mu^k)\xi + (\psi^{k'}X - 2\gamma^{k'})\beta + (\tau\mathbf{e} + \alpha^k - \delta^k)'z + (\kappa\mathbf{e} - \alpha^k - \delta^k)'u - \psi^{k'}y.
\end{aligned}$$

Se puede escribir entonces el problema de optimización relajado $L(\mathcal{X}_{\overline{\mathcal{C}_{1,2}}}, \lambda^k)$, donde $\mathcal{X}_{\overline{\mathcal{C}_{1,2}}}$ es el conjunto de todas las restricciones no relajadas en la función lagrangiana anterior.

$$(L(\mathcal{X}_{\bar{\mathcal{C}}_{1,2}}, \lambda^k)) \quad \min_{\beta, z, u, \xi} \quad (\xi - \mu^k)\xi + \left(\psi^{k'}X - 2\gamma^{k'}\right)\beta \quad (4.16a)$$

$$+ (\tau \mathbf{e} + \alpha^k - \delta^k)' z$$

$$+ (\kappa \mathbf{e} - \alpha^k - \delta^k)' u - \psi^{k'} y$$

$$\text{s.a.} \quad u \in \mathbb{R}_+^m, \quad (4.16b)$$

$$z \in \mathbb{R}_+^m, \quad (4.16c)$$

Se explorarán entonces las tres alternativas de relajación propuestas en esta subsección, esperando encontrar la más eficiente en términos de tiempos de ejecución entre ellas.

4.2.5. Sobre la convergencia de la relajación lagrangiana $L(\mathcal{X}, \lambda^k)$

El método de descomposición descrito con el Algoritmo 2 asume que el problema de optimización derivado de la relajación lagrangiana $L(\mathcal{X}, \lambda^k)$ entrega una solución óptima. Sin embargo, esto no es necesariamente cierto, ya que las variables duales λ^k derivan del problema maestro $P(\mathcal{S}^k)$ descrito en (4.13), el cual puede tener una forma dual muy distinta a la del problema cónico original (4.12). Para dejar esto aún más claro, se presenta el problema dual $D(\mathcal{S}^k)$ del problema maestro $P(\mathcal{S}^k)$, en el caso en que se construye $\mathcal{S}^k$ a través de las combinaciones lineales las soluciones previas del método (π no tiene condiciones extra de la forma (4.13d)), como

$$(D(\mathcal{S}^k)) \quad \max_{\psi, \mu, \alpha, \gamma, \delta} \quad -\frac{\mu^2}{4} - \psi' y$$

$$\text{s.a.} \quad (\tau \mathbf{e} + \alpha - \delta)' \mathbf{Z}^k + (\kappa \mathbf{e} - \alpha - \delta)' \mathbf{U}^k$$

$$+ (\psi' X - 2\gamma') \mathbf{B}^k = 0 \quad (4.17a)$$

$$\begin{pmatrix} \psi \\ \mu \end{pmatrix} \in \mathcal{L}_{n+1} \quad (4.17b)$$

$$\begin{pmatrix} \alpha_i \\ \gamma_i \\ \delta_i \end{pmatrix} \in \mathcal{L}_3, \quad i = 1, \dots, m, \quad (4.17c)$$

Al considerar la restricción sobre π de pertenencia a $\mathbb{R}^{v_0+k-1}$ como en la combinación afín o convexa, lo único que cambia en el problema $D(\mathcal{S}^k)$ es que la nulidad del término en la restricción (4.17a) se convierte en la pertenencia a $\mathbb{R}^{v_0+k-1}$ de este (todas sus componentes positivas). En cuanto a la restricción de suma de los elementos de π igual a uno, esta restricción genera una nueva variable dual ν , la cual agrega un término extra “ $-\nu$ ” a la función objetivo y un término extra “ $+\nu$ ” en cada componente de los vectores de la restricción (4.17a).

En lo que sigue, se analizarán las condiciones necesarias para la convergencia de la relajación de cada una de las tres alternativas presentadas en la subsección anterior, con el fin de analizar si el problema dual (4.17) las garantiza o no.

4.2.5.1. Condiciones necesarias para la convergencia de $L(\mathcal{X}_{\bar{\mathcal{C}}_1}, \lambda^k)$

La función objetivo (4.14a) del problema $L(\mathcal{X}_{\bar{\mathcal{C}}_1}, \lambda^k)$ esta escrita de tal manera que se pueda analizar cada variable del problema por separado. En primer lugar, ya se mencionó que se puede encontrar de el mínimo con respecto a ξ con las condiciones de primer orden. En cuanto al resto de las variables, si no existieran las restricciones cónicas de segundo orden (4.14b), para asegurar la convergencia de la función objetivo de la relajación sería necesario que se cumplieran las condiciones:

1. $\psi^{k'} X = 0$, dado que β no tiene restricciones de naturaleza.
2. $\tau \mathbf{e}, \kappa \mathbf{e} \in \mathbb{R}_+^m$, dado que $z, u \in \mathbb{R}_+^m$.

La segunda de estas condiciones se tiene por construcción, dado que para el problema de selección siempre se escogen $\tau, \kappa \in \mathbb{R}_{++}$, mientras que la primera de estas condiciones no está asegurada, ya que no es una restricción de las variables duales λ^k del problema dual maestro $D(\mathcal{S}^k)$, de manera que no necesariamente convergería la función objetivo por si sola en un comienzo. Sin embargo, al existir las restricciones cónicas de la forma (4.14b), y recordando que son equivalentes a $\beta_i^2 \leq z_i u_i$, los pesos asociados a z_i y u_i en la función objetivo pueden evitar que la variable β_i diverja en cualquier sentido, dependiendo de sus valores.

Si se toman valores de peso tales que $\tau = \kappa$, se tiene, por simetría del problema con respecto a z y u , que el óptimo del problema cumple $z^* = u^*$ y que se llega a la igualdad en la restricción cónica $\beta_i^{*2} = z_i^* u_i^*$, por lo que el óptimo cumple $|\beta_i^*| = z_i^* = u_i^*$. Sin pérdida de generalidad, se pueda tomar un subconjunto factible del mismo problema, tal que $\beta_i^2 = z_i u_i$, el cual alcanza el mismo valor óptimo, ya que su función objetivo es necesariamente mayor o igual por ser un subconjunto de la región factible, y el óptimo del problema $L(\mathcal{X}_{\overline{C_1}}, \lambda^k)$ es factible en él, por lo que alcanzan el mismo valor en la función objetivo en el óptimo. Los únicos términos que dependen de estas tres variables en la función objetivo del problema son de la forma

$$(X'\psi^k)_i \beta_i + \tau |\beta_i| + \kappa |\beta_i| = (X'\psi^k)_i \beta_i + 2\tau |\beta_i|$$

Estos se pueden separar en los casos de las componentes no-negativas $\beta_i \geq 0$ y las negativas $\beta_i < 0$. Si $\beta_i \geq 0$, entonces este término es de la forma

$$\begin{aligned} (X'\psi^k)_i \beta_i + 2\tau |\beta_i| &= (X'\psi^k)_i \beta_i + 2\tau \beta_i \\ &= ((X'\psi^k)_i + 2\tau) \beta_i \end{aligned}$$

Como $\beta_i \geq 0$, necesariamente se debe cumplir que $(X'\psi^k)_i + 2\tau \geq 0$ para que la función objetivo no diverja al minimizar con respecto a β_i , lo que es equivalente a $-(X'\psi^k)_i \leq 2\tau$. En el caso en que $\beta_i < 0$, el término de la función objetivo toma la forma

$$\begin{aligned} (X'\psi^k)_i \beta_i + 2\tau |\beta_i| &= (X'\psi^k)_i \beta_i - 2\tau \beta_i \\ &= ((X'\psi^k)_i - 2\tau) \beta_i \end{aligned}$$

Como ahora $\beta_i < 0$, se debe cumplir que $(X'\psi^k)_i - 2\tau \leq 0$ para que la función objetivo no diverja, lo que es equivalente a $(X'\psi^k)_i \leq 2\tau$. Resumiendo las dos condiciones, para que la función objetivo del problema $L(\mathcal{X}_{\overline{C_1}}, \lambda^k)$ (4.14) converja en este caso, se debe cumplir la condición de convergencia

$$|(X'\psi^k)_i| \leq 2\tau, \quad \forall i \in \{1, \dots, m\}. \quad (4.18)$$

El problema con esta condición es que se cumple sólo si es que $\tau = \kappa$. No obstante, por Proposición 1, se sabe que para cualquier parámetro $\tau \neq \kappa$ existen parámetros que forman un problema equivalente tales que $\tilde{\tau} = \tilde{\kappa}$. Teniendo esto en cuenta, se aplica la misma condición en ambos problemas, por lo que basta con transformar (4.18) con pesos $\tilde{\tau} = \tilde{\kappa} = \alpha\tau$ a su versión equivalente con $\kappa = \alpha^2\tau$ como sigue

$$\begin{aligned} |(X'\psi^k)_i| &\leq 2\tilde{\tau}, & \forall i \in \{1, \dots, m\} \\ \iff |(X'\psi^k)_i| &\leq 2\alpha\tau, & \forall i \in \{1, \dots, m\} \\ \iff |(X'\psi^k)_i| &\leq 2\sqrt{\kappa\tau}, & \forall i \in \{1, \dots, m\}, \end{aligned} \quad (4.19)$$

siendo esta última la condición de convergencia general, para cualquier valor de τ y κ . Notar que si se toman $\tau = \kappa$ se recupera la condición (4.18). Por lo tanto, basta con una componente del vector $(X'\psi^k)$ que no cumpla la condición para que el problema diverja.

4.2.5.2. Condiciones necesarias para la convergencia de $L(\mathcal{X}_{\mathcal{C}_2}, \lambda^k)$

Para el caso del problema relajado $L(\mathcal{X}_{\mathcal{C}_2}, \lambda^k)$ presentando en (4.15), se da un comportamiento similar al antes expuesto. Existen tres conjuntos de variables completamente independientes entre sí en este problema: z , u y ξ junto con β , al estar relacionadas con la restricción cónica de segundo orden. Dicho esto, se pueden analizar las condiciones de convergencia por casos. Para el caso de ξ y β , se puede obviar la existencia de la variable auxiliar ξ al eliminar la restricción cónica (4.15b) y volver a forma original de la norma $\|y - X\beta\|_2^2$ en la función objetivo, con lo que el término dependiente de la variable β en la función objetivo queda como

$$\|y - X\beta\|_2^2 - 2\gamma^{k'}\beta = y'y - 2y'X\beta + \beta'X'X\beta - 2\gamma^{k'}\beta,$$

lo que es una función convexa con respecto a β , ya que $X'X \in S_+^m$ (matriz semidefinida positiva en $\mathbb{R}^{m \times m}$); por lo tanto, al no tener restricciones sobre esta variable, se puede imponer un punto silla para encontrar un mínimo de esta función con las condiciones de primer orden, para obtener el óptimo $\beta^* = (X'X)^{-1}(X'y + \gamma^k)$, asumiendo $X'X \in S_{++}^m$, matriz definida positiva. Dicho esto, no es necesario imponer condiciones con respecto a este término en la función objetivo, ya que basta computar el resultado óptimo para él.

Con respecto a las variables z y u , las condiciones son evidentes. Al tener sólo restricciones de positividad sobre las componentes de estos vectores, cualquier ponderación negativa por alguna de estas en la función objetivo genera divergencia a $-\infty$; es decir, las únicas condiciones necesarias para la convergencia del problema relajado $L(\mathcal{X}_{\bar{\mathcal{C}}_2}, \lambda^k)$ son

$$\tau \mathbf{e} + \alpha^k - \delta^k \in \mathbb{R}_+^m \quad (4.20)$$

$$\kappa \mathbf{e} - \alpha^k - \delta^k \in \mathbb{R}_+^m \quad (4.21)$$

Ninguna de estas condiciones es asegurada por el problema dual $D(\mathcal{S}^k)$, por lo que cualquier componente que no las cumpla en alguna iteración del método de descomposición genera un quiebre en este, al no entregar una solución numérica para la relajación.

4.2.5.3. Condiciones necesarias para la convergencia de $L(\mathcal{X}_{\bar{\mathcal{C}}_{1,2}}, \lambda^k)$

En este último caso, el modelo relajado $L(\mathcal{X}_{\bar{\mathcal{C}}_{1,2}}, \lambda^k)$ presentado en (4.16) no tiene ninguna restricción que relacione a ninguna de sus variables, por lo que las condiciones de convergencia se ven de manera directa. Con respecto a la variable auxiliar ξ , se una función convexa con el término $(\xi - \mu^k)\xi$, para el cual ya se mencionó que se puede forzar un punto silla, mientras que la variable β es completamente libre, por lo que puede divergir hacia cualquier dirección y sentido, por lo que el coeficiente que la acompaña se debe anular para poder converger con respecto a ella. Por último, con respecto a las variables z y u es análogo al caso anterior, ya que los términos son idénticos. Dicho esto, las condiciones necesarias para la convergencia de este problema vienen dadas por

$$X'\psi^k - 2\gamma^k = 0 \quad (4.22)$$

$$\tau\mathbf{e} + \alpha^k - \delta^k \in \mathbb{R}_+^m \quad (4.23)$$

$$\kappa\mathbf{e} - \alpha^k - \delta^k \in \mathbb{R}_+^m \quad (4.24)$$

Dado que, nuevamente, ninguna de estas condiciones para las variables duales λ^k viene asegurada por el problema dual $D(\mathcal{S}^k)$, entonces se tiene que si cualquier componente de alguna de estas condiciones no las cumple, entonces el problema relajado diverge, con lo que no se tienen soluciones para añadir al método de descomposición.

En la Tabla 4.1 se presenta un resumen de todas las condiciones de convergencia necesarias, para los tres distintos tipos de problema relajado, presentadas en esta subsección.

Tabla 4.1: Resumen de las condiciones necesarias para asegurar la convergencia de las tres versiones de relajación del problema cónico de segundo orden.

Problema relajado	Condiciones de convergencia
$L(\mathcal{X}_{\overline{\mathcal{C}}_1}, \lambda^k)$	$ (X'\psi^k)_i \leq 2\sqrt{\kappa\tau}, \quad \forall i \in \{1, \dots, m\}$
$L(\mathcal{X}_{\overline{\mathcal{C}}_2}, \lambda^k)$	$\tau\mathbf{e} + \alpha^k - \delta^k \in \mathbb{R}_+^m,$ $\kappa\mathbf{e} - \alpha^k - \delta^k \in \mathbb{R}_+^m$
$L(\mathcal{X}_{\overline{\mathcal{C}}_{1,2}}, \lambda^k)$	$X'\psi^k - 2\gamma^k = 0,$ $\tau\mathbf{e} + \alpha^k - \delta^k \in \mathbb{R}_+^m,$ $\kappa\mathbf{e} - \alpha^k - \delta^k \in \mathbb{R}_+^m$

4.2.6. Soluciones artificiales para problemas relajados divergentes

Tal y como se puede concluir de la subsección anterior, pueden darse casos en donde las variables del problema dual $D(\mathcal{S}^k)$ (4.17) no cumplan las condiciones de convergencia, dado que el problema dual no asegura ninguna de ellas, lo que generaría que los problemas relajados en cuestión diverjan. Naturalmente, si esto pasa, pierde sentido el método de descomposición,

ya que no se puede obtener una solución finita de un problema que diverge, por lo que no se podría generar un conjunto $\mathcal{S}^{k+1}$ con una nueva solución para la siguiente iteración del método. Existe entonces una necesidad de generar soluciones de algún modo alternativo para que el método siga iterando en estos casos.

Una solución simple es generar soluciones canónicas, asociadas a las componentes de la variable principal β , de manera aleatoria; es decir, asignar una probabilidad uniforme a cada $i \in \{1, \dots, m\}$ para obtener algún índice j , generando una solución artificial de la forma $\bar{\beta}^k = \mathbf{e}_j$, donde la única componente no-nula es la j -ésima. Para las otras dos variables principales, basta con tomar el mismo vector $\bar{z}^k = \bar{u}^k = \mathbf{e}_j$ cuando $\tau = \kappa$, o sus equivalentes en proporción, $\bar{z}^k = \sqrt{\kappa/\tau} \mathbf{e}_j$ y $\bar{u}^k = \sqrt{\tau/\kappa} \mathbf{e}_j$, cuando $\tau \neq \kappa$, para mantener la estructura de las soluciones óptimas.

Se puede seguir desarrollando la idea anterior, si se tiene en cuenta que todas las condiciones de convergencia de la subsección anterior son sobre ponderaciones de la forma $h(\lambda^k)'x$ en la función objetivo de cada problema, donde $h(\lambda^k)$ es alguna transformación de las variables duales λ^k (constante en el problema relajado), y x es el vector de las variables del problema relajado. Si el problema fuera una minimización de la función $L(x, \lambda^k) = h(\lambda^k)'x$ de manera irrestricta, entonces la dirección de mayor descenso de esta función con respecto a x está dada por $-\nabla_x L(x, \lambda^k) = -h(\lambda^k)$. En los casos en que $x_j \rightarrow \pm\infty$ al resolver el problema; es decir, las componentes j del vector $h(\lambda^k)$ que no cumplan las condiciones de convergencia, estos valores divergen justamente en las direcciones $-\nabla_x L(x, \lambda^k)_j = -h(\lambda^k)_j$, por lo que se podría pensar en tomar las componentes de la dirección de mayor descenso en las componentes que no cumplan con las condiciones de convergencia, expuestas en la subsección anterior. Sin embargo, la solución $\bar{x}^k$ con las componentes divergentes iguales a las de $-h(\lambda^k)$, y el resto de componentes no necesariamente es una buena solución para el método al ser una mezcla de componentes de máximo descenso y valores nulos. Por lo tanto, se propone tomar múltiples vectores canónicos en las componentes divergentes, ponderador por el signo de $-h(\lambda)_j^k$ en caso de ser variables libres en el problema, y simplemente vectores canónicos en las componentes divergentes para las variables positivas, lo que da más libertad al método para encontrar la mejor dirección entre las componentes divergentes y el resto de soluciones previas, además de ser un paso más allá de la elección aleatoria de

vectores canónicos, mientras que se hace el mismo emparejamiento de componentes de β , z y u descrito con las soluciones canónicas aleatorias. El problema que puede surgir de este método es que se sumen demasiadas soluciones sintéticas canónicas, por la posibilidad de tener muchas las componentes divergentes, lo que puede complejizar el problema maestro de la siguiente interacción, al aumentar demasiado la dimensionalidad de $\mathcal{S}^{k+1}$. Para evitar esto, se agrega un parámetro v al método, que dicta la cantidad de soluciones canónicas a agregar, escogiendo las v de mayor valor absoluto en su ponderador, en cada iteración donde exista divergencia en el problema relajado.

Si se denota por $\mathcal{J}_v^k$ al conjunto de las v componentes de mayor magnitud entre las que no cumplen con la condición de convergencia de su problema relajado respectivo, se puede explicitar el procedimiento de la construcción de soluciones artificiales $\bar{x}^k = (\bar{\beta}^k, \bar{z}^k, \bar{u}^k)$ para cada problema propuesto, en el resumen de la Tabla 4.2.

Tabla 4.2: Resumen de las condiciones de convergencia y las soluciones artificiales construidas en cada caso cuando existe divergencia del problema relajado. Todas las componentes de soluciones artificiales no explicitadas $j \notin \mathcal{J}_v^k$ son nulas.

Problema relajado	Condiciones de convergencia	Soluciones artificiales
$L(\mathcal{X}_{\bar{C}_1}, \lambda^k)$	$ (X'\psi^k)_i \leq 2\sqrt{\kappa\tau}, \quad \forall i \in \{1, \dots, m\}$	$\sqrt{\tau/\kappa} \bar{z}_j^k = \sqrt{\kappa/\tau} \bar{u}_j^k = 1,$ $\bar{\beta}_j^k = -\frac{(X'\psi^k)_j}{ (X'\psi^k)_j }, \forall j \in \mathcal{J}_v^k$
$L(\mathcal{X}_{\bar{C}_2}, \lambda^k)$	$\tau \mathbf{e} + \alpha^k - \delta^k \in \mathbb{R}_+^m$	$\sqrt{\tau/\kappa} \bar{z}_j^k = \sqrt{\kappa/\tau} \bar{u}_j^k = 1,$ $\bar{\beta}_j^k = \pm 1, \forall j \in \mathcal{J}_v^k$
	$\kappa \mathbf{e} - \alpha^k - \delta^k \in \mathbb{R}_+^m$	$\sqrt{\tau/\kappa} \bar{z}_j^k = \sqrt{\kappa/\tau} \bar{u}_j^k = 1,$ $\bar{\beta}_j^k = \pm 1, \forall j \in \mathcal{J}_v^k$
$L(\mathcal{X}_{\bar{C}_{1,2}}, \lambda^k)$	$X'\psi^k - 2\gamma^k = 0$	$\sqrt{\tau/\kappa} \bar{z}_j^k = \sqrt{\kappa/\tau} \bar{u}_j^k = 1,$ $\bar{\beta}_j^k = -\frac{(X'\psi^k - 2\gamma^k)_j}{ (X'\psi^k - 2\gamma^k)_j }, \forall j \in \mathcal{J}_v^k$
	$\tau \mathbf{e} + \alpha^k - \delta^k \in \mathbb{R}_+^m$	$\sqrt{\tau/\kappa} \bar{z}_j^k = \sqrt{\kappa/\tau} \bar{u}_j^k = 1,$ $\bar{\beta}_j^k = \pm 1, \forall j \in \mathcal{J}_v^k$
	$\kappa \mathbf{e} - \alpha^k - \delta^k \in \mathbb{R}_+^m$	$\sqrt{\tau/\kappa} \bar{z}_j^k = \sqrt{\kappa/\tau} \bar{u}_j^k = 1,$ $\bar{\beta}_j^k = \pm 1, \forall j \in \mathcal{J}_v^k$

Luego de construir los vectores $\bar{\beta}^k$ de soluciones artificiales, sus componentes no nulas

se separan en distintos vectores, para que cada una represente una nueva columna en el problema maestro.

Como las condiciones antes detalladas no dependen de ningún resultado de problemas relajados, se puede omitir el intento de resolución de estos problemas cuando alguna componente no cumpla el criterio de convergencia, ahorrando así este tiempo de resolución en el método de descomposición.

Capítulo 5

Resultados

Todos los resultados presentados en este capítulo se obtuvieron con un mismo computador, con las siguientes especificaciones:

1. Procesador: AMD Ryzen 7 4800HS, 2.90 GHz, de 8 núcleos y 16 hilos.
2. RAM: 16,0 GB (15,4 GB de uso).
3. OS: Windows 11 22H2, 64-bit.

5.1. Datos

Se trabaja con dos tipo de datos: sintéticos y una instancia real. En cuanto a los datos sintéticos, dada una cantidad n de observaciones y m atributos deseados, se generan la matriz de variables independientes X , donde sus columnas son m arreglos distintos de variables aleatorias que siguen una distribución normal $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$, con sus parámetros nuevamente variables aleatorias que distribuyen uniformes $\mu_i \sim U(-10, 10)$ y $\sigma_i \sim U(0, 5)$. Los coeficientes reales β se generan con otra distribución $U(-5, 5)$, similar a los parámetros anteriores, mientras que el vector objetivo y se obtiene con la ecuación $y = X\beta$.

Para que los datos antes descritos se asemejen a una base de datos común, luego de obtener el vector objetivo y , se transforma un 10 % de las columnas de X en ruido, el cual

sigue una distribución $\mathcal{N}(0, 1)$, obteniendo así una nueva matriz $\tilde{X}$, la cual es utilizada como input para todos los modelos testeados en el capítulo de resultados.

5.2. Método de descomposición, según el problema relajado

5.2.1. Tiempos de ejecución preliminares, según el problema relajado

Los resultados para tiempos de ejecución del modelo cónico, y los tres tipos de método de descomposición, para cada uno de los tres problemas relajados presentados en la subsección 4.2.4, incorporando también las soluciones artificiales, en casos de divergencia, descritas en la subsección 4.2.6, se presentan en las Figuras 5.1, 5.2 y 5.3. Para las tres figuras se consideran las configuraciones de parámetros , $\tau = \kappa = \|y - X\beta_{OLS}\|_2^2$, $v_0 = 6$, $v = \max\{\lfloor 0,012m \rfloor, 5\}$. Se establece un límite de tiempo de ejecución de 30 minutos para todos los métodos y se resuelven las instancias con el solver MOSEK.

Se puede apreciar que el método de descomposición que relaja las restricciones cónicas $\mathcal{C}_2$ es el más lento de todos, llegando a tiempos superiores a los 30 minutos para instancias de datos sintéticos con $m = 500$ o más atributos, lo que está muy por encima del tiempo del SOCP (4.12), el cual es capaz de resolver la instancia sintética de $m = 500$ atributos en aproximadamente 37 segundos. Algo similar sucede con el método de descomposición que relaja todas las restricciones cónicas de segundo orden $\mathcal{C}_{1,2}$, el cual supera los 30 minutos para instancias de $m = 900$ o más atributos, mientras que el SOCP es capaz de resolver la instancia de $m = 900$ atributos en aproximadamente 1 minuto y 53 segundos. Ninguno de estos dos métodos es capaz de superar en tiempos de ejecución al problema cónico original en ninguna instancia, por lo que pierde el sentido el método de descomposición con estas relajaciones.

En cuanto al método de descomposición que relaja la restricción cónica de segundo orden contenida en $\mathcal{C}_1$, se puede apreciar que para instancias desde $m = 4000$ atributos, el méto-




Figura 5.1: Tiempos de ejecución con datos sintéticos para distintos números de atributos m , con $n = 10000$ observaciones.




Figura 5.2: Caption

do de descomposición es sistemáticamente más rápido de resolver que el SOCP, llegando a resolver una instancia de $m = 10000$ atributos en menos de 20 minutos, mientras que el problema cónico original supera los 30 minutos de ejecución para instancias de $m = 4000$




Figura 5.3: Caption

atributos o más. Es necesario destacar que en la instancia de $m = 3000$ atributos, el método de descomposición relajando las restricciones de $\mathcal{C}_1$ resuelve el problema en aproximadamente 19 segundos, mientras que el SOCP resuelve esta instancia en un tiempo aproximado de 22 minutos y 37 segundos; es decir, el problema original es un 70% más lento que el método de descomposición en cuestión, por lo que el método de descomposición sí es capaz, con esta relajación, de resolver instancias grandes del problema cónico original en tiempos considerablemente menores.

5.2.2. Valor objetivo óptimo, según el problema relajado

Para confirmar que el método de descomposición realmente está entregando el resultado óptimo para las distintas instancias del problema (4.12), es necesario también revisar que en las instancias anteriores, el método esté entregando la misma solución óptima, y también su valor objetivo asociado, dada cierta tolerancia. Para ello, se presentan los símiles de las figuras de la subsección anterior en cuanto a instancias, pero para diferencias relativas de los valores objetivos óptimos de cada versión del método de descomposición con respecto al problema cónico de segundo orden, en las Figuras 5.4, 5.5 y 5.6.

Se define la diferencia relativa de los valores objetivos óptimos ($DRVO$) del método de descomposición con relajación de los conjuntos de restricciones cónicos $\mathcal{C}$ ($CG - L_C$) y del SOCP como

$$DRVO_{CG-L_C} = \frac{f(x_{CG-L_C}^*) - f(x_{SOCP}^*)}{f(x_{SOCP}^*)}, \quad (5.1)$$

donde $f(x_{CG-L_C}^*)$ es el valor objetivo óptimo del método $CG - L_C$ y $f(x_{SOCP}^*)$ es el valor objetivo óptimo del problema cónico original.




Figura 5.4: Caption

Se puede apreciar que la mayor desviación con respecto al valor objetivo óptimo del problema cónico de segundo orden se da en la Figura 5.4, con el método de descomposición que relaja el conjunto de restricciones $\mathcal{C}_2$ en la instancia con $m = 20$ atributos, donde la diferencia relativa es de -8%, por lo que el valor objetivo del método $CG - L_{C2}$ es un 8% mayor al del problema original. Sin embargo, esto es una instancia pequeña, por lo que no se espera que sea necesario utilizar ningún método de descomposición en ella. Las instancias de interés son las de gran tamaño, con $m = 1000$ o más atributos, y, como se puede ver en la Figura 5.6, la mayor diferencia relativa entre las tres instancias de gran tamaño es de




Figura 5.5: Caption




Figura 5.6: Caption

-2e-5 %, lo que, en efectos prácticos, dada la tolerancia predefinida, es el mismo valor objetivo óptimo del SOCP. Se puede concluir entonces que el valor objetivo óptimo de los métodos de descomposición en estas instancias es el mismo que el del problema cónico de segundo orden, y, por ende, en estas instancias, son problemas equivalentes.

5.3. Revisión de criterios de convergencia en modelos relajados

En cuanto a los criterios de convergencia de los métodos de descomposición, existe una oportunidad de mejora en cuanto a tiempos de ejecución, ya que al conocer las condiciones de convergencia y las soluciones artificiales que se deben implementar en cada caso, tal y como se muestra en la Tabla 4.1, es posible revisar estas condiciones de manera previa a la resolución del problema relajado respectivo; es decir, evitar la resolución de los problemas relajados que divergen y sólo generar las soluciones artificiales.

Para los resultados presentados en esta subsección se ocupan los mismo parámetros antes mencionados, excepto el peso de castigos, el cual cambia a $\tau = \kappa = \|y - X\beta_{OLS}\|_2^2 / \sqrt{M}$, con lo que se tiene un castigo menor en función del tamaño de la instancia. La finalidad de esto es poder mostrar instancias del problema con más iteraciones, lo que da más oportunidades de ver qué sucede con los problemas relajados.

5.3.1. Comportamiento de la relajación lagrangiana a través de iteraciones

Para ver qué tan seguido no se cumplen las condiciones de convergencia, se presentan los valores objetivo óptimos y los tiempos de ejecución del problema maestro $P(\mathcal{S}^k)$ y el problema relajado $L(\mathcal{X}_{\bar{\mathcal{C}}}, \lambda^k)$, a través de las iteraciones del método $CG - L_C$, en las Figuras 5.7 y 5.8.

En estas figuras se puede observar que siempre existe un tiempo de ejecución para la relajación lagrangiana, en cada iteración, pero no así para su valor óptimo. Esto quiere decir que se resolvió el problema, pero que el valor objetivo diverge en todas las iteraciones, menos la última, por lo que la mayoría del tiempo invertido en intentar resolver el problema relajado es tiempo perdido. En detalle, el tiempo de resolución invertido en cada iteración, y la fracción invertida en la resolución de problemas relajados se puede apreciar en la Tabla 5.1.




Figura 5.7: Caption




Figura 5.8: Caption

Se puede ver que las resoluciones de los problemas relajados alcanzan un 15.91 % del tiempo total del método, por lo que valdría la pena intentar reducir este tiempo.

Tabla 5.1: Tiempos de ejecución (en minutos) y valor objetivo para el método de descomposición y sus subproblemas, sin chequeo previo de condiciones de convergencia.

	t	Valor objetivo
Método de descomposición	9.11	74328058.97
Problema maestro	7.41	74328058.97
Relajación lagrangiana	1.45	74328058.98

5.3.2. Omisión del problema relajado con condiciones de convergencia

Si se implementa la opción de revisar las condiciones de convergencia previo a intentar resolver la relajación, se obtiene los resultados de las Figuras 5.9 y 5.10, para la misma instancia de la subsección anterior.




Figura 5.9: Caption

En este caso, la condición de convergencia identifica correctamente los casos de divergencia del problema relajado, y sólo se intenta resolver este en la última iteración, donde el valor óptimo converge.




Figura 5.10: Caption

Para tener la comparación exacta, se presentan los tiempos de resolución en cada subproblema del método por iteración en la Tabla 5.2. En esta tabla se puede observar que el valor óptimo objetivo es el mismo que en la Tabla 5.1, por lo que se resolvió el mismo problema, y en la misma cantidad de iteraciones también. El tiempo dedicado a la relajación lagrangiana del problema pasó de 1.45 minutos a aproximadamente 3.34 segundos. Este valor se puede ver afectado por distintos factores, al ser solo una instancia, pero la diferencia es considerablemente grande de todos modos, y es claro que se ahorra casi todo el tiempo de resolución de la relajación lagrangiana.

Tabla 5.2: Tiempos de ejecución (en minutos) y valor objetivo para el método de descomposición y sus subproblemas, con chequeo previo de condiciones de convergencia.

	t	Valor objetivo
Total método	7.36	74328058.97
Problema maestro	7.24	74328058.97
Relajación lagrangiana	0.06	74328058.98

Para comprobar más instancias, y también revisar qué sucede al aplicar el mismo método

con el resto de los métodos, se presentan en la Tabla 5.3 los tiempos de ejecución de los tres métodos de descomposición, para distintos tamaños de instancias.

5.4. Ajuste de parámetros del método

Los parámetros del método de descomposición que se pueden variar para resolver un mismo problema son, en su mayoría, parámetros que afectan en la construcción de los conjuntos de soluciones $\mathcal{S}^k$. El foco se centrará en analizar los resultados para distintos valores de estos parámetros, y así seleccionar aquellos parámetros que disminuyen los tiempos de ejecución, sin afectar en gran medida la exactitud del método.

5.4.1. Construcción del conjunto de soluciones iniciales $\mathcal{S}^0$

El conjunto de soluciones iniciales, tal y como se menciona en la construcción de los conjuntos $\mathcal{S}^k$ de la subsección 4.2.2, tiene distintas opciones para la construcción de soluciones iniciales, las cuales se dividen en las dos subsecciones de resultados siguientes.

5.4.1.1. Construcción de soluciones iniciales

En primer lugar, se analizan las diferencias del método de descomposición con la relajación $L(\mathcal{X}_{\overline{C_1}}, \lambda^k)$ con distintas maneras de construir las soluciones iniciales, o el conjunto factible inicial $\mathcal{S}^0$. Tal y como se menciona en el capítulo de Metodología, se analizan las siguientes dos opciones para su construcción.

1. Agregar a la matriz inicial $\mathbf{B}^0$ una columna con un vector de soluciones constantes con coeficientes de módulo 1; es decir, agregar una solución tal que $|\beta_i^0| = 1, \forall i \in \{1, \dots, m\}$, y, para las matrices $\mathbf{Z}^0$ y $\mathbf{U}^0$, tomar vectores z^0, u^0 con todas sus componentes iguales a 1. Como se debe escoger un signo para las componentes de β^0 , pero no se sabe qué signo es el que mejor comportamiento tendrá en cada componente, se escoge el signo de cada una de estas componentes de manera aleatoria, pero se mantiene la unidad en

Tabla 5.3: Comparación de tiempos de ejecución (en minutos) con y sin revisión previa de condiciones de convergencia, para los tres tipos de relajación.

Relajación	m	t original	t con omisión	$DRVO$
$L(\mathcal{X}_{\overline{C_1}}, \lambda^k)$	100	0.30	0.21	0
	200	0.72	0.52	0
	300	2.07	1.57	0
	400	4.58	3.64	0
	500	4.77	3.76	0
	600	4.47	3.65	0
	700	5.29	4.09	0
	800	6.25	4.89	0
	900	6.79	5.31	0
$L(\mathcal{X}_{\overline{C_2}}, \lambda^k)$	100	1.03	1.02	0
	200	4.9	4.94	0
	300	13.81	13.45	0
	400	—	—	—
	500	—	—	—
	600	—	—	—
	700	—	—	—
	800	—	—	—
	900	—	—	—
$L(\mathcal{X}_{\overline{C_{1,2}}}, \lambda^k)$	100	2.44	2.41	0
	200	3.43	3.38	0
	300	4.63	4.61	0
	400	—	—	—
	500	—	—	—
	600	—	—	—
	700	—	—	—
	800	—	—	—
	900	—	—	—

las componentes de los otros dos vectores de soluciones.

2. Agregar a la matriz inicial $\mathbf{B}^0$ una cantidad v_0 de vectores con una única componente de módulo uno, pero con distintos signos en la componente asociada a β_0 , al igual que en el caso anterior, y el resto de componente nulas. Para el caso de las matrices $\mathbf{Z}^0$ y $\mathbf{U}^0$, se agregan vectores canónicos con un uno en la misma componente no nula de los β^0 . Para tener una base comparativa para este tipo de soluciones, se agregará también la opción de construir soluciones con componentes aleatorias con valores 0, 1 y -1 para los vectores β^0 , mientras que los otros dos vectores se rellenan con unos en las componentes no nulas de β^0 .

En la Tabla 5.4 se presentan los resultados promedio de tiempo, en minutos, para distintas instancias, con 10 intentos por cada configuración de parámetros y cantidad de atributos. También se presentan el número de instancias exitosas, la desviación del tiempo de ejecución, el número de atributos promedio seleccionados, el número de iteraciones promedio y el valor objetivo promedio, con el fin de poder analizar con mayor precisión el comportamiento de las distintas configuraciones.

Se ve que las soluciones canónicas aceleran el método en cualquier caso, mientras que la solución constante pareciera aumentar los tiempos de ejecución, lo que se ve de manera más clara en las instancias con soluciones iniciales canónicas. Sin embargo, pareciera ser que las instancias sin soluciones canónicas son menos estables, dado que son las únicas oportunidades en donde existen instancias fallidas. También se estabiliza el tipo de solución agregando una solución constante, dado que la cantidad de atributos seleccionados se mantiene similar en cualquier caso, mientras que donde no hay solución constante existe mayor variabilidad entre configuraciones. De todos modos, las soluciones son numéricamente equivalentes, ya que la función objetivo es la misma en términos de tolerancia.

En principio, se escoge como mejor configuración la construcción de únicamente soluciones canónicas, priorizando el tiempo de ejecución, y, en instancias con mayor inestabilidad de convergencia, se optará por agregar además la solución constante a las matrices iniciales de soluciones.

Tabla 5.4: Caption

Configuración			Métricas					
m	sol. cte.	sol. canónicas	# éxitos	t prom.	t desv.	# atr.	# iter.	valor obj.
1000	False	False	10	0.174	0.040	3.000	2.400	8.371673e+07
		True	10	0.126	0.004	3.200	2.000	8.371673e+07
	True	False	10	0.158	0.034	3.000	2.200	8.371673e+07
		True	10	0.141	0.004	3.000	2.000	8.371673e+07
2000	False	False	10	1.638	0.023	92.000	6.000	2.127228e+08
		True	9	0.604	0.050	95.000	5.556	2.127228e+08
	True	False	10	1.775	0.372	92.000	6.200	2.127228e+08
		True	10	1.444	0.252	92.000	5.400	2.127228e+08
3000	False	False	10	1.678	0.227	51.000	4.100	2.658656e+08
		True	9	0.576	0.072	58.111	3.222	2.658655e+08
	True	False	10	1.845	0.352	51.000	4.300	2.658656e+08
		True	10	1.316	0.303	51.200	3.500	2.658656e+08
4000	False	False	10	0.889	0.008	3.000	2.000	3.262936e+08
		True	10	0.577	0.005	21.100	2.000	3.262936e+08
	True	False	10	0.898	0.014	3.000	2.000	3.262936e+08
		True	10	0.879	0.013	3.000	2.000	3.262936e+08
5000	False	False	10	4.097	0.723	79.200	4.100	4.558798e+08
		True	7	1.083	0.116	108.000	3.286	4.558796e+08
	True	False	10	3.831	0.042	79.100	4.000	4.558798e+08
		True	10	3.465	0.997	79.500	3.800	4.558798e+08

5.4.1.2. Cantidad de soluciones iniciales

El segundo parámetro a variar en términos de la construcción del conjunto factible inicial $\mathcal{S}^0$, es la cantidad de soluciones iniciales canónicas a considerar; es decir, variar el tamaño del parámetro v_0 . Para ello, se varía este en función de la cantidad de parámetros del problema. Si se escoge un $v_0 = m$, entonces se tiene el problema cónico original, por lo que se debe escoger una cantidad considerablemente menor, teniendo en cuenta el gran tamaño de m .

En la Tabla 5.5 se muestran los resultados de instancias con v_0 entre 1 y $m/4$. Se puede apreciar que, a medida que la fracción de soluciones iniciales canónicas $\frac{v_0}{m}$ aumenta, el tiempo de resolución del método también lo hace. Sin embargo, si se escoge una única solución inicial, se obtienen soluciones menos estables en convergencia, dado que algunas de estas instancias no convergen, y, además, cambia drásticamente el número promedio de atributos seleccionados

Tabla 5.5: Caption

Configuración		Métricas					
m	v_0	# éxitos	t prom.	t desv.	# atr.	# iter.	valor obj.
1000	1	10	0.123	0.004	5.100	2.000	8.371673e+07
	51	10	0.185	0.028	3.200	2.100	8.371673e+07
	101	10	0.238	0.020	3.100	2.000	8.371673e+07
	151	10	0.304	0.046	3.100	2.100	8.371673e+07
	201	10	0.374	0.044	3.100	2.100	8.371673e+07
	251	10	0.465	0.070	3.900	2.100	8.371673e+07
2000	1	7	0.648	0.045	96.000	5.857	2.127228e+08
	101	10	0.839	0.025	96.800	5.000	2.127228e+08
	201	10	1.268	0.058	95.600	5.000	2.127228e+08
	301	10	1.761	0.051	95.600	5.000	2.127228e+08
	401	10	2.416	0.078	94.300	5.000	2.127228e+08
	501	10	3.106	0.226	95.000	4.900	2.127228e+08
3000	1	7	0.595	0.075	62.857	3.429	2.658655e+08
	151	10	0.814	0.025	52.900	3.000	2.658656e+08
	301	10	1.274	0.054	52.800	3.000	2.658656e+08
	451	10	1.874	0.066	52.400	3.000	2.658656e+08
	601	10	2.657	0.100	53.300	3.000	2.658656e+08
	751	10	3.641	0.120	53.000	3.000	2.658656e+08
4000	1	9	0.571	0.007	35.889	2.000	3.262936e+08
	201	10	0.827	0.023	11.600	2.000	3.262936e+08
	401	10	1.304	0.074	9.700	2.000	3.262936e+08
	601	9	1.980	0.066	8.111	2.000	3.262936e+08
	801	10	2.870	0.097	10.300	2.000	3.262936e+08
	1001	10	4.092	0.171	13.600	2.000	3.262936e+08
5000	1	5	1.140	0.123	122.000	3.600	4.558796e+08
	251	10	1.640	0.042	87.200	3.000	4.558797e+08
	501	10	2.783	0.069	90.900	3.000	4.558797e+08
	751	9	4.418	0.063	110.889	3.000	4.558797e+08
	1001	10	6.781	0.721	94.100	3.100	4.558797e+08
	1251	10	9.028	0.196	123.300	3.000	4.558797e+08

(no así el valor objetivo). Dicho esto, se optará por escoger un valor pequeño, pero con mayor consistencia en las soluciones.

En la Tabla 5.6 se puede apreciar que los tiempos promedio de ejecución parecen ser

Tabla 5.6: Caption

Configuración		Métricas					
m	v_0	# éxitos	t prom.	t desv.	# atr.	# iter.	valor obj.
1000	1	10	0.122	0.004	5.100	2.000	8.371673e+07
	11	10	0.132	0.014	3.100	2.100	8.371673e+07
	21	10	0.135	0.006	3.100	2.000	8.371673e+07
	31	10	0.149	0.003	3.300	2.000	8.371673e+07
	41	10	0.160	0.011	3.200	2.000	8.371673e+07
	51	10	0.170	0.012	3.200	2.000	8.371673e+07
2000	1	7	0.649	0.014	98.286	6.000	2.127228e+08
	21	10	0.590	0.012	95.900	5.000	2.127228e+08
	41	10	0.668	0.039	96.400	5.100	2.127228e+08
	61	10	0.712	0.023	96.900	5.000	2.127228e+08
	81	10	0.779	0.048	97.000	5.100	2.127228e+08
	101	10	0.842	0.044	96.200	5.000	2.127228e+08
3000	1	9	0.621	0.066	58.778	3.556	2.658655e+08
	31	10	0.581	0.015	53.200	3.000	2.658656e+08
	61	10	0.618	0.015	53.100	3.000	2.658656e+08
	91	10	0.677	0.014	53.000	3.000	2.658656e+08
	121	10	0.740	0.026	52.700	3.000	2.658656e+08
	151	10	0.816	0.015	53.200	3.000	2.658656e+08
4000	1	8	0.579	0.005	40.750	2.000	3.262936e+08
	41	10	0.618	0.007	15.300	2.000	3.262936e+08
	81	10	0.671	0.019	8.900	2.000	3.262936e+08
	121	10	0.727	0.026	15.300	2.000	3.262936e+08
	161	10	0.784	0.021	9.800	2.000	3.262936e+08
	201	10	0.839	0.023	9.000	2.000	3.262936e+08
5000	1	3	1.136	0.141	116.333	3.667	4.558797e+08
	51	10	1.058	0.014	89.300	3.000	4.558797e+08
	101	10	1.156	0.018	86.800	3.000	4.558797e+08
	151	9	1.268	0.025	91.111	3.000	4.558797e+08
	201	10	1.426	0.039	88.300	3.000	4.558797e+08
	251	10	1.554	0.035	88.100	3.000	4.558797e+08

menores en instancias con v_0 entre 1 y un 2 % de m , siendo las instancias con una solución las que nuevamente tienen muchas instancias fallidas, mientras que para v_0 cercanos al 1 – 2 % de m , todas las instancias son exitosas. Sin embargo, las diferencias entre tiempos de ejecución entre estas configuraciones no es suficientemente grande, siendo las instancias cercanas al 2 % de m las que parecen tomar un mayor tiempo en general. Se utilizará en adelante cualquier

valor de este parámetro en el rango antes mencionado.

5.4.2. Construcción del conjunto factible $\mathcal{S}^k$

Para la construcción del conjunto factible del problema maestro, $\mathcal{S}^k$, se barajan distintas opciones, ya descritas con anterioridad.

1. Los cuatro distintos tipos de combinación de soluciones descritos en la subsección 4.2.2.
2. La cantidad de soluciones artificiales a agregar en iteraciones donde la relajación lagrangiana diverge, descritas en la subsección 4.2.6.

5.4.2.1. Tipo de combinación de soluciones

Para el tipo de combinación a utilizar, existen cuatro opciones: combinación convexa, combinación afín, combinación cónica y combinación lineal. Estas combinaciones se pueden resumir con dos restricciones distintas sobre las variables π del problema maestro $P(\mathcal{S}^k)$ (4.13): $\sum_j \pi_j = 1$ y $\pi \geq 0$.

En la Tabla 5.7 se pueden ver los mismos resultados de las tablas anteriores, pero para las distintas combinaciones de las dos restricciones de combinaciones antes mencionadas. En ella se pueden apreciar dos comportamientos críticos con respecto a la combinación convexa y afín, las cuales incluyen la restricción $\sum_j \pi_j = 1$, ya que en estas dos combinaciones existen muchas instancias fallidas, llegando a tener incluso a no tener instancias del problema con resultados en ciertas configuraciones. El segundo comportamiento extraño es que en estas mismas combinaciones se observa que el valor óptimo de la función objetivo es distinto al de las combinaciones cónica y lineal. Analizando con mayor detalle las instancias exitosas de las combinaciones convexa y afín, se observa que en ellas las soluciones artificiales creadas en las últimas iteraciones se repiten a través de estas; es decir, no se agregan nuevas soluciones artificiales, si no que se repiten los mismos vectores, con lo que el problema maestro tiene la misma región factible en las iteraciones finales de la instancia ($\mathcal{S}^{k+1} = \mathcal{S}^k$). Esta situación no se da con la combinación cónica y lineal, donde siempre se tienen soluciones nuevas entre las soluciones artificiales.

El problema antes descrito puede ser explicado en gran parte con la naturaleza de las soluciones artificiales, dado que estas soluciones constan de vectores con componentes de magnitud unitaria o nula, por lo que una combinación convexa entre ellos sólo puede generar valores coeficientes $\beta^k = \mathbf{B}^k \pi$ con componentes entre -1 y 1 ($-1 \leq \beta_i^k \leq 1$), y componentes entre 0 y 1 para z^k y u^k ; es decir, con este tipo de combinación y soluciones artificiales no se pueden obtener resultados para problemas generales, con lo que rápidamente se podría estancar el problema en la mejor solución posible de dicha naturaleza, lo que ciertamente no es el óptimo del problema original, el cual tiene un óptimo con coeficientes de distintas magnitudes. En cuanto a la combinación afín, no es exactamente el mismo problema, pero sí muy similar, dado que también se restringe el valor de los coeficientes entre sí, donde, para que un coeficiente sea de gran magnitud, deben existir suficientes coeficientes distinto a este, de signo contrario, de manera tal que se contrarresten dichas magnitudes en la restricción $\sum_j \pi_j = 1$, por lo que también se distorsiona el espacio completo de soluciones posibles, y, por tanto, el resultado óptimo.

Teniendo en cuenta que las combinaciones con restricción $\sum_j \pi_j = 1$ no sirven para problemas de este tipo, se puede seguir analizar la Tabla 5.7 con respecto a las combinaciones cónica ($\pi \geq 0$) y lineal. Se puede apreciar que tanto los tiempos de ejecución de estos dos tipos de combinaciones son bastante similares, por lo que no se puede concluir que una combinación sea mejor que otra. En principio, para restringir lo menos posible al problema maestro, se escoge la combinación lineal, sin restricciones sobre π , como la predeterminada para el método de descomposición.

5.4.2.2. Cantidad de soluciones artificiales

El último parámetro que influye en la construcción del conjunto factible $\mathcal{S}^k$ es la cantidad de soluciones artificiales v que se agregan en cada iteración donde la relajación lagrangiana diverge. Al igual que con v_0 , se presentan los resultados para distintas configuración de v , con valores entre 1 y $m/4$ soluciones en la Tabla 5.8, en donde se puede apreciar que existe un aumento en el tiempo de ejecución a medida que crece el valor de v con respecto a m , pero con una disminución de este entre la solución única y el 5% de la cantidad de atributos total m . Se puede ver entonces que el mejor rendimiento en cuanto a eficiencia en tiempos de ejecución

Tabla 5.7: Caption

Configuración			Métricas					
m	$\sum_j \pi_j = 1$	$\pi \geq 0$	# éxitos	t prom.	t desv.	# atr.	# iter.	valor obj.
1000	False	False	10	0.142	0.018	3.200	2.200	8.371673e+07
		True	10	0.133	0.006	3.400	2.000	8.371673e+07
	True	False	10	0.271	0.021	3.000	3.100	8.371673e+07
		True	10	2.073	0.167	3.900	13.600	8.371673e+07
2000	False	False	10	0.530	0.013	94.800	4.000	2.127228e+08
		True	10	0.586	0.119	94.600	4.200	2.127228e+08
	True	False	0	—	—	—	—	—
		True	1	0.477	—	43.000	5.000	1.238704e+09
3000	False	False	10	0.615	0.076	55.400	3.000	2.658656e+08
		True	10	0.613	0.008	61.200	3.000	2.658656e+08
	True	False	10	0.516	0.075	42.900	3.800	4.611430e+08
		True	8	0.542	0.076	39.000	3.875	4.611430e+08
4000	False	False	10	0.675	0.010	20.500	2.000	3.262936e+08
		True	10	0.680	0.013	26.100	2.000	3.262936e+08
	True	False	10	1.794	0.408	6.500	2.800	3.262688e+08
		True	0	—	—	—	—	—
5000	False	False	10	1.162	0.032	110.300	3.000	4.558797e+08
		True	10	1.155	0.015	114.700	3.000	4.558797e+08
	True	False	3	1.129	0.373	95.000	4.333	1.129547e+09
		True	2	1.032	0.417	74.500	4.000	1.129547e+09

se obtiene entre 1 y 10 %, obteniendo soluciones poco consistentes en configuraciones con una única solución.

Para analizar con mayor detalle el intervalo antes mencionado, se muestran en la Tabla 5.9 los resultados para distintos intervalos equi-espaciados entre 1 y aproximadamente un 10 % de los m atributos disponibles en la base de datos. En esta tabla se observa que los menores tiempos se obtienen con una cantidad de soluciones artificiales v de entre aproximadamente un 2 – 5 % de m , con aparentemente menores tiempos en un 3 %, pero con diferencias no lo suficientemente grandes como para concluir que dicho porcentaje es el mejor valor para v . Dicho esto, se toman los valores del intervalo 2 – 5 % de la cantidad total de atributos m como uno suficientemente bueno para el método de descomposición.

Tabla 5.8: Caption

Configuración		Métricas					
m	v	# éxitos	t prom.	t desv.	# atr.	# iter.	valor obj.
1000	1	10	0.191	0.004	3.000	4.0	8.371673e+07
	51	10	0.158	0.026	3.100	2.1	8.371673e+07
	101	10	0.180	0.016	3.100	2.0	8.371673e+07
	151	10	0.216	0.022	3.000	2.0	8.371673e+07
	201	10	0.284	0.080	3.100	2.1	8.371673e+07
	251	10	0.295	0.025	3.000	2.0	8.371673e+07
2000	1	10	8.542	0.193	92.100	91.7	2.127228e+08
	101	10	0.484	0.013	98.500	3.0	2.127228e+08
	201	10	0.638	0.163	99.200	2.7	2.127228e+08
	301	10	0.667	0.261	103.800	2.3	2.127228e+08
	401	10	1.001	0.678	102.200	2.4	2.127228e+08
	501	10	1.032	0.481	110.900	2.2	2.127228e+08
3000	1	10	6.226	0.085	51.300	51.7	2.658656e+08
	151	10	0.528	0.013	65.600	2.0	2.658656e+08
	301	10	0.682	0.031	65.500	2.0	2.658656e+08
	451	10	0.979	0.316	61.900	2.1	2.658656e+08
	601	10	1.160	0.038	54.500	2.0	2.658656e+08
	751	10	1.497	0.052	56.800	2.0	2.658656e+08
4000	1	10	0.852	0.061	3.100	3.8	3.262936e+08
	201	10	0.736	0.015	26.900	2.0	3.262936e+08
	401	9	0.995	0.029	3.667	2.0	3.262936e+08
	601	10	1.373	0.091	4.500	2.0	3.262936e+08
	801	9	1.840	0.050	7.222	2.0	3.262936e+08
	1001	10	2.370	0.096	6.000	2.0	3.262936e+08
5000	251	10	1.312	0.308	184.000	2.5	4.558797e+08
	501	10	1.412	0.032	189.900	2.0	4.558797e+08
	751	10	1.961	0.054	297.500	2.0	4.558797e+08
	1001	10	2.638	0.075	201.000	2.0	4.558797e+08
	1251	10	3.564	0.102	132.700	2.0	4.558797e+08

5.5. Variación de penalización del modelo

En esta sección, se analizará el comportamiento de las soluciones y los tiempos de ejecución del método de descomposición al variar los parámetros de penalización del problema τ y κ . Estos parámetros cambian el problema, dado que se asignan pesos distintos en la función objetivo a las variables que acotan a los coeficientes β , por lo que la cantidad de atributos

Tabla 5.9: Caption

Configuración		Métricas					
m	v	# éxitos	t prom.	t desv.	# atr.	# iter.	valor obj.
1000	1	10	0.198	0.007	3.000	4.000	8.371673e+07
	17	10	0.152	0.027	3.100	2.200	8.371673e+07
	33	10	0.146	0.014	3.100	2.100	8.371673e+07
	49	10	0.160	0.012	3.100	2.000	8.371673e+07
	65	10	0.159	0.009	3.100	2.000	8.371673e+07
	81	10	0.170	0.009	3.200	2.000	8.371673e+07
	97	10	0.189	0.019	3.000	2.000	8.371673e+07
2000	1	9	8.659	0.192	92.444	92.000	2.127228e+08
	34	10	0.525	0.010	97.200	4.000	2.127228e+08
	67	10	0.482	0.090	97.500	3.100	2.127228e+08
	100	10	0.490	0.016	100.900	3.000	2.127228e+08
	133	10	0.607	0.114	98.000	3.100	2.127228e+08
	166	10	0.596	0.115	97.800	2.800	2.127228e+08
	199	10	0.566	0.172	102.100	2.500	2.127228e+08
3000	1	10	6.408	0.091	51.100	51.900	2.658656e+08
	51	10	0.605	0.005	53.600	3.000	2.658656e+08
	101	10	0.547	0.101	60.800	2.300	2.658656e+08
	151	10	0.556	0.092	62.400	2.100	2.658656e+08
	201	10	0.742	0.202	67.900	2.400	2.658656e+08
	251	10	0.682	0.153	70.800	2.100	2.658656e+08
	301	10	0.697	0.026	64.000	2.000	2.658656e+08
4000	1	10	0.891	0.008	3.000	4.000	3.262936e+08
	67	10	0.648	0.015	7.000	2.000	3.262936e+08
	133	10	0.693	0.018	26.600	2.000	3.262936e+08
	199	10	0.757	0.011	7.000	2.000	3.262936e+08
	265	10	0.818	0.018	34.400	2.000	3.262936e+08
	331	10	0.914	0.030	10.000	2.000	3.262936e+08
	397	10	1.014	0.032	7.800	2.000	3.262936e+08
5000	1	0	—	—	—	—	—
	84	10	1.128	0.017	97.300	3.000	4.558797e+08
	167	10	1.094	0.193	163.000	2.400	4.558797e+08
	250	9	1.152	0.254	152.222	2.222	4.558797e+08
	333	9	1.313	0.346	186.333	2.222	4.558797e+08
	416	9	1.273	0.048	201.778	2.000	4.558797e+08
	499	8	1.394	0.020	112.500	2.000	4.558797e+08

seleccionados debería ir variando a medida que se modifica este valor; es decir, el método debería seleccionar menos atributos a medida que el valor de τ y κ crece.

Tabla 5.10: Caption

Configuración			Métricas					
m	M exp.	τ, κ	# éxitos	t prom.	t desv.	# atr.	# iter.	valor obj.
1000	0.10	3.612079e+06	10	0.094	0.001	0.000	1.000	8.381992e+07
	0.15	2.557156e+06	10	0.094	0.002	0.000	1.000	8.381992e+07
	0.20	1.810328e+06	10	0.094	0.002	0.000	1.000	8.381992e+07
	0.25	1.281614e+06	10	0.094	0.002	0.000	1.000	8.381992e+07
	0.30	9.073132e+05	10	0.094	0.001	0.000	1.000	8.381992e+07
	0.35	6.423286e+05	10	0.142	0.008	2.800	2.000	8.380291e+07
	0.40	4.547338e+05	10	0.143	0.009	3.000	2.000	8.371744e+07
	0.45	3.219269e+05	10	0.190	0.022	7.300	2.800	8.361017e+07
	0.50	2.279068e+05	10	0.283	0.014	51.400	4.000	8.316589e+07
	0.55	1.613456e+05	10	0.683	0.073	164.000	7.100	8.049651e+07
	0.60	1.142240e+05	9	1.616	0.127	283.111	11.111	7.438074e+07
	0.65	8.086438e+04	9	3.093	0.521	383.778	14.778	6.573946e+07
	0.70	5.724760e+04	7	4.766	0.615	467.000	18.000	5.614936e+07
2000	0.10	6.129905e+06	10	0.332	0.055	18.100	2.400	5.485915e+08
	0.15	4.191816e+06	10	0.364	0.081	27.600	2.400	4.377981e+08
	0.20	2.866492e+06	10	0.310	0.013	31.200	2.000	3.573301e+08
	0.25	1.960195e+06	10	0.428	0.058	46.200	3.000	2.999105e+08
	0.30	1.340441e+06	10	0.434	0.015	64.400	3.000	2.591516e+08
	0.35	9.166346e+05	10	0.434	0.013	82.900	3.000	2.302122e+08
	0.40	6.268227e+05	10	0.460	0.014	103.100	3.000	2.095732e+08
	0.45	4.286405e+05	10	0.611	0.011	127.400	4.000	1.946852e+08
	0.50	2.931175e+05	10	0.659	0.078	154.700	4.100	1.833811e+08
	0.55	2.004427e+05	9	1.253	0.149	255.333	6.222	1.734837e+08
	0.60	1.370688e+05	8	3.693	0.623	463.125	10.375	1.602735e+08
	0.65	9.373186e+04	9	7.092	1.193	681.778	13.667	1.415956e+08
	0.70	6.409671e+04	8	11.454	1.238	860.500	16.500	1.199601e+08
3000	0.10	7.892754e+06	10	0.549	0.135	12.400	2.300	4.297481e+08
	0.15	5.288987e+06	10	0.518	0.083	21.700	2.200	3.823837e+08
	0.20	3.544185e+06	10	0.514	0.060	28.000	2.100	3.426887e+08
	0.25	2.374982e+06	10	0.507	0.060	33.900	2.100	3.123373e+08
	0.30	1.591491e+06	10	0.507	0.057	42.200	2.100	2.901962e+08
	0.35	1.066469e+06	10	0.511	0.059	51.900	2.100	2.743998e+08
	0.40	7.146480e+05	10	0.647	0.091	66.100	2.800	2.632429e+08
	0.45	4.788904e+05	10	0.681	0.010	87.300	3.000	2.553003e+08
	0.50	3.209076e+05	10	0.897	0.072	116.800	3.900	2.493132e+08
	0.55	2.150423e+05	10	1.449	0.044	257.100	5.000	2.422794e+08
	0.60	1.441013e+05	10	4.239	0.475	560.500	8.500	2.261919e+08
	0.65	9.656325e+04	6	11.170	1.080	916.500	12.667	2.001789e+08
	0.70	6.470768e+04	2	19.568	2.606	1219.000	15.500	1.690386e+08
4000	0.10	8.516049e+06	10	0.463	0.008	0.000	1.000	3.262979e+08
	0.15	5.625163e+06	10	0.462	0.004	0.000	1.000	3.262979e+08
	0.20	3.715627e+06	10	0.464	0.004	0.000	1.000	3.262979e+08
	0.25	2.454308e+06	10	0.476	0.009	0.000	1.000	3.262979e+08
	0.30	1.621161e+06	10	0.478	0.008	0.000	1.000	3.262979e+08
	0.35	1.070836e+06	10	0.472	0.006	0.000	1.000	3.262979e+08
	0.40	7.073269e+05	10	0.697	0.023	8.000	2.000	3.262692e+08
	0.45	4.672154e+05	10	0.928	0.136	73.300	2.700	3.261103e+08
	0.50	3.086130e+05	9	1.267	0.231	148.556	3.556	3.248313e+08
	0.55	2.038502e+05	6	2.569	0.429	392.000	5.500	3.147816e+08
	0.60	1.346506e+05	4	7.644	0.235	810.750	9.000	2.886823e+08
	0.65	8.894164e+04	2	18.664	0.002	1248.500	13.000	2.503677e+08
	0.70	6.470768e+04	2	19.568	2.606	1219.000	15.500	1.690386e+08
5000	0.10	8.975859e+06	10	1.044	0.266	44.100	2.300	8.362816e+08
	0.15	5.863103e+06	10	0.907	0.016	50.900	2.000	7.094421e+08
	0.20	3.829826e+06	10	0.918	0.010	52.500	2.000	6.151192e+08
	0.25	2.501673e+06	10	0.898	0.013	60.500	2.000	5.483146e+08
	0.30	1.634113e+06	10	1.118	0.180	86.300	2.600	5.022115e+08
	0.35	1.067416e+06	10	0.955	0.113	91.600	2.100	4.705226e+08
	0.40	6.972444e+05	10	1.063	0.196	163.800	2.400	4.486613e+08
	0.45	4.554456e+05	9	1.291	0.025	185.333	3.000	4.334541e+08
	0.50	2.975007e+05	8	1.667	0.213	246.000	3.750	4.215086e+08
	0.55	1.943298e+05	5	4.114	0.126	593.600	6.000	4.007345e+08
	0.60	1.269378e+05	1	10.708	—	1125.000	9.000	3.600078e+08
	0.65	8.291679e+04	1	28.023	—	1631.000	13.000	3.056644e+08

Capítulo 6

Conclusiones

Trabajo futuro:

1. Ocupar el problema dual del maestro en vez del maestro y asegurar que se cumplan las restricciones de vivir en conos duales (esto se cumple ya, porque en el problema maestro también se arma el dual con conos. LAs que fallan son las otras. No es el mismo dual) y las de que no se vaya a $-\infty$ el lagrangiano.
2. Resolver el método con el dual $D(\mathcal{S}^k)$ en vez del primal maestro. De esta manera puede ser más rápido y también se pueden restringir valores de las variables duales en vez de generar soluciones sintéticas.
3. Se puede construir un conjunto inicial $\mathcal{S}_0$ de manera inteligente, no sólo de manera aleatoria.

Conclusiones:

1. Sparsity de $\mathcal{C}_2$ hace que no sean tan costosas como la densa $\mathcal{C}_1$
2. Las combinaciones convexa y afín no sirven para este caso, por el tema de las soluciones artificiales. Quizás se podría ocupar un valor en función de la restricción violada para intentar armar soluciones con sentido que puedan aportar dentro de una combinación convexa.

Bibliografía

- Aha, D. W. and Bankert, R. L. (1996). *A Comparative Evaluation of Sequential Feature Selection Algorithms*, pages 199–206. Springer New York, New York, NY.
- Aizawa, A. (2003). An information-theoretic perspective of tf-idf measures. *Information Processing & Management*, 39(1):45–65.
- Bellman, R. E. (1957). *Dynamic Programming*. Princeton University Press, Princeton, New Jersey.
- Benders, J. F. (1962). Partitioning procedures for solving mixed-variables programming problems. *Numerische Mathematik*, 4(1):238–252.
- Bertsimas, D., King, A., and Mazumder, R. (2016). Best subset selection via a modern optimization lens. *The Annals of Statistics*, 44(2):813 – 852.
- Boyd, S. P. and Vandenberghe, L. (2004a). Convex optimization. In *Convex optimization*, pages 136–146. Cambridge University Press.
- Boyd, S. P. and Vandenberghe, L. (2004b). The lagrange dual function. In *Convex optimization*, pages 215–223. Cambridge University Press.
- Boyd, S. P. and Vandenberghe, L. (2004c). Mathematical optimization. In *Convex optimization*, pages 1–4. Cambridge University Press.
- Boyd, S. P. and Vandenberghe, L. (2004d). Optimality conditions. In *Convex optimization*, pages 241–249. Cambridge University Press.
- Chen, R.-C., Dewi, C., Huang, S.-W., and Caraka, R. E. (2020). Selecting critical features for data classification based on machine learning methods. *Journal of Big Data*, 7(1).

- Chicoisne, R. (2023). Computational aspects of column generation for nonlinear and conic optimization: classical and linearized schemes. *Computational Optimization and Applications*.
- Cui, Y., Jin, J. S., Zhang, S., Luo, S., and Tian, Q. (2010). Correlation-based feature selection and regression. In Qiu, G., Lam, K. M., Kiya, H., Xue, X.-Y., Kuo, C.-C. J., and Lew, M. S., editors, *Advances in Multimedia Information Processing - PCM 2010*, pages 25–35, Berlin, Heidelberg. Springer Berlin Heidelberg.
- Curry, H. B. (1944). The method of steepest descent for non-linear minimization problems. *Quarterly of Applied Mathematics*, 2(3):258–261.
- Dantzig, G. B. and Wolfe, P. (1961). The decomposition algorithm for linear programs. *Econometrica*, 29(4):767.
- Ding, C. and Peng, H. (2005). Minimum redundancy feature selection from microarray gene expression data. *Journal of Bioinformatics and Computational Biology*, 03(02):185–205.
- Fletcher, R. (2013). Newton-like methods. In *Practical Methods of Optimization*, pages 44–79. John Wiley & Sons, Ltd.
- Guyon, I., Weston, J., Barnhill, S., and Vapnik, V. (2002). Gene selection for cancer classification using support vector machines. *Machine Learning*, 46(1/3):389–422.
- Holland, J. H. (1975). Adaptation in natural and artificial systems: An introductory analysis with applications to biology, control, and artificial intelligence. *University of Michigan Press, Ann Arbor. (2nd Edition, MIT Press, 1992.)*.
- Hou, Z., Hu, Q., and Nowinski, W. (2006). On minimum variance thresholding. *Pattern Recognition Letters*, 27(14):1732–1743.
- Karbowski, A. (2021). Generalized benders decomposition method to solve big mixed-integer nonlinear optimization problems with convex objective and constraints functions. *Energies*, 14(20):6503.
- Karush, W. (1939). Minima of functions of several variables with inequalities as side conditions. Master’s thesis, Department of Mathematics, University of Chicago, Chicago, IL, USA.

- Kenney, A., Chiaromonte, F., and Felici, G. (2021). MIP-BOOST: Efficient and Effective L0 Feature Selection for Linear Regression. *Journal of Computational and Graphical Statistics*, 30(3):566–577.
- Kohavi, R. and John, G. H. (1997). Wrappers for feature subset selection. *Artificial Intelligence*, 97(1):273–324. Relevance.
- Kucukyavuz, S., Shojaie, A., Manzour, H., Wei, L., and Wu, H.-H. (2020). Consistent second-order conic integer programming for learning bayesian networks.
- Lemaréchal, C. (2001). *Lagrangian Relaxation*, pages 112–156. Springer Berlin Heidelberg, Berlin, Heidelberg.
- Miao, J. and Niu, L. (2016). A survey on feature selection. *Procedia Computer Science*, 91:919–926. Promoting Business Analytics and Quantitative Management of Technology: 4th International Conference on Information Technology and Quantitative Management (ITQM 2016).
- Nowak, I. (2005). *Relaxation and Decomposition Methods for Mixed Integer Nonlinear Programming*. Birkhäuser Basel.
- Özlem, N., ÖZGÜR, A., and GÜRGEN, F. (2021). A novel gene selection method for gene expression data for the task of cancer type classification. *Biology Direct*, 16(1).
- Pearson, K. (1900). X. on the criterion that a given system of deviations from the probable in the case of a correlated system of variables is such that it can be reasonably supposed to have arisen from random sampling. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, 50(302):157–175.
- Pearson, K. (1901). LIII. On lines and planes of closest fit to systems of points in space. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, 2(11):559–572.
- Quinlan, J. R. (1986). Induction of decision trees. *Machine Learning*, 1(1):81–106.
- Richards, J. A. (2022). *Supervised Classification Techniques*, pages 263–367. Springer International Publishing, Cham.

- Rothlauf, F. (2011). *Optimization Methods*, pages 45–102. Springer Berlin Heidelberg, Berlin, Heidelberg.
- Schwendinger, B., Schwendinger, F., and Vana, L. (2022). Holistic generalized linear models.
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society. Series B (Methodological)*, 58(1):267–288.
- Vicente, L. N. and Calamai, P. H. (1994). Bilevel and multilevel programming: A bibliography review. *Journal of Global Optimization*, 5(3):291–306.
- Zou, H. and Hastie, T. (2005). Regularization and Variable Selection Via the Elastic Net. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 67(2):301–320.